



Asociación Mexicana de Geofísicos  
de Exploración, A.C.

Segunda Generación

Volumen 4 | Número 2 | Abril-Junio 2021

## Inteligencia Artificial en Geociencias



**Caracterización Sísmica Empleando Algoritmos de Inteligencia Artificial para la Propagación de Propiedades de Roca en el Modelado Estático.**



**Uso de Inteligencia Artificial en la Distribución de Facies Elásticas Relacionadas a el Tren de Compactación de los Yacimientos Clásticos de la Formación de Chicantepec.**



**Obtención de la Velocidad de Corte y Parámetros Elásticos - Geomecánicos, Utilizando Redes Neuronales.**



**Flujo Tecnológico Aplicado a la Identificación de Facies Sísmicas Calibradas con Información de Pozos en Áreas de Exploración Aguas Profundas.**





## Asociación Mexicana de Geofísicos de Exploración, A.C.

### COMITÉ EJECUTIVO AMGE 2020-2022

**Gerardo Clemente Martínez**  
Presidente

**Humberto Salazar Soto**  
Vicepresidente

**Juan Manuel Nájera García**  
Secretario

**Rodolfo Rocha Ruiz**  
Tesorero

**Efraín Méndez Hernández**  
Editor

**Raúl Del Valle García**  
Editor

#### Presidentes Delegacionales:

- Rubén Darío Martínez Macías, Delegación Houston
- Amador Guerra Reyna, Delegación Reynosa
- José Cámara Alfaro, Delegación Tampico
- Carlos Rosas Lara, Delegación Poza Rica
- Gabriel González Covarrubias, Delegación Veracruz
- Francisco Rubén Rocha de la Vega, Delegación CDMX
- Guadalupe Torres Acuña, Delegación Villahermosa
- José Alberto Santana Fernández, Delegación Cd. Del Carmen

**Las opiniones expresadas en esta publicación son responsabilidad exclusiva de los autores y no reflejan necesariamente las del Comité Ejecutivo AMGE ni la de los editores.**

Para someter manuscritos en el Boletín Técnico AMGE – Segunda Generación, así como conocer las normas editoriales y guía de publicación, favor de comunicarse con alguno de los siguientes editores:



**Raúl del Valle García**  
Email: raul.vontal@gmail.com



**Efraín Méndez Hernández**  
Email: emendez2310@gmail.com

#### DERECHOS DE AUTOR

El Boletín Técnico de la AMGE, Segunda Generación, es publicado por la Asociación Mexicana de Geofísicos de Exploración, A.C., Campo Tamulte 117, Col. Carrizal, Villahermosa Centro, Tabasco, C.P. 86038. El título del Boletín, así como el contenido, se encuentran debidamente autorizados y protegidos. Publicado trimestralmente por la Asociación Mexicana de Geofísicos de Exploración, A.C., Volumen 4, Número 2, Abril-Junio 2021.

#### SOBRE ARTÍCULOS

Los artículos del Boletín Técnico AMGE, en su Segunda Generación, son presentados a nuestros socios bajo el respaldo de textos técnicos recibidos y arbitrados por el Comité Editorial o bien que han sido difundidos en el Congreso Mexicano del Petróleo, de manera anual, manteniendo un formato establecido, las autorizaciones respectivas, y el arbitrio de un comité de expertos en la materia.

Esta edición reproduce las imágenes de origen y el contenido de los autores, con la corrección de estilo correspondiente con el fin de efectuar mejoras de calidad editorial para nuestros lectores.

#### COLABORADORES



- **Director:** Carlos Pozos
- **Editores:** Francisco Abad, Rebeca Sánchez
- **Diseño:** José Tepezano  
solucioncuatro.4@gmail.com

# Editorial

Distinguidos socios AMGE, nos es grato presentarles esta edición del Boletín Técnico AMGE, Segunda Generación, V4, No 2, Abril-Junio 2021, bajo el tema: Inteligencia Artificial en Geociencias.

Estamos siendo testigos de una sociedad basada en la información y en un entorno evolutivo de redes de comunicación, por lo que es relevante generar tecnología que procese, analice e interprete gran cantidad de datos, como es el caso de las aplicaciones en geociencias para la industria petrolera.

Cabe mencionar que la Inteligencia Artificial (IA), es el concepto más amplio de que las máquinas son capaces de realizar tareas de una manera que consideraríamos "inteligente". El aprendizaje automático es una aplicación particular de la IA basada en la idea de que realmente deberíamos poder dar acceso de los datos a las máquinas y dejar que aprendan por sí mismas. Generalmente, los algoritmos de redes neuronales (RN), son utilizados para el proceso de aprendizaje automático, pero hay otras tendencias, por ejemplo, utilizando máquinas de soporte vectorial que maximizan las distancias entre "hiperplanos" multidimensionales, que permiten obtener las diferentes clases posibles involucradas en el proceso de clasificación a partir de algoritmos de optimización.

Para esta edición se presentan cuatro trabajos que utilizan diferentes algoritmos de RN, los cuales han tenido un gran salto tecnológico en el presente siglo, debido a la incorporación de nuevas herramientas matemáticas que se aprovechan nítidamente para el desempeño, exactitud y evaluación de incertidumbre en las diferentes aplicaciones cuantitativas de las disciplinas de las geociencias. Herramientas matemáticas utilizadas, van desde la incorporación de procesos de optimización, como son los algoritmos evolutivos (genéticos), componentes principales, funciones de densidad de probabilidad, teorema de Bayes, técnicas estadísticas para exploración de datos, y otros aspectos matemáticos, físicos y geológicos que ayudan a comprender la naturaleza de los datos, su interrelación, así como a fortalecer el proceso de aprendizaje.

El primer trabajo por Mata García y otros, consiste en la aplicación del modelado de RN y algoritmos genéticos para la optimización de patrones de correlación no lineal, a través de la función de activación Sigmoide entre trazas sísmicas apiladas y propiedades de roca. Dado que la función de activación transmite la información generada por la combinación no lineal de los pesos y las entradas, es deseable encontrar la mejor combinación de los pesos a partir de algún algoritmo de optimización global. La aplicación de un algoritmo genético durante la fase de aprendizaje del análisis de RN, reduce el riesgo de encontrar una solución en un mínimo local. Para dicho análisis, se considera una ventana de tiempo acorde con la resolución sísmica y se toman en cuenta trazas circundantes al pozo para los cálculos, ayudando a evitar encontrar sólo una solución local y estabilizando la salida. Los autores obtuvieron mejores resultados de la correlación del volumen de arcilla y porosidad, por lo que se generaron estimaciones de estas propiedades en el volumen sísmico, siendo calibradas con 70 pozos de estudio. Dichos cubos de propiedades, fueron utilizados posteriormente en la generación de un modelo de facies, tipo de roca, porosidad, volumen de arcilla y permeabilidad. Las propiedades finales son calibradas con información de pozo, análisis geoestadístico y funciones de correlación. El trabajo muestra un ejemplo atractivo de la caracterización sísmica con ilustraciones de buena calidad. Hubiese sido deseable mostrar mapas de incertidumbre para la toma de decisiones.

El segundo trabajo, de Montilla et al., es una interesante aplicación de las RN para estimar facies elásticas y su relación con el tren de compactación en yacimientos clásicos de Chicontepec, dado el propósito de entender su relación con la calidad de la roca almacén, que en este caso se relaciona con el contenido de mineral de calcita. El estudio se basa en crear relaciones entre las facies determinadas en un grupo de pozos e impedancias. La descripción de facies en los pozos se definió mediante un análisis de gráficas cruzadas de propiedades de roca y propiedades elásticas, mostrando que la relación de impedancias permitía una clara discriminación de litología. Así se logró obtener una distribución de la calidad de las arenas (con mayor o



menor contenido de calcita), calibrada con los pozos. Para la inversión sísmica, se realizó un procesamiento adecuado de los datos preapilados arrojando valores de impedancias y sus correspondientes propiedades elásticas, las cuales se utilizaron para la extrapolación de las facies con la metodología propuesta de RN. Se describe someramente el algoritmo de RN utilizado, donde particularmente en la parte de clasificación, es necesario estimar las probabilidades condicionales en un esquema bayesiano para obtener las probabilidades de cada facie definida. Se logró con éxito mostrar mapas de la calidad de rocas. Desafortunadamente, algunas figuras del artículo no presentan buena calidad.

El tercer artículo de López Aguirre y coautores, muestra la aplicación de las RN para predecir la velocidad de corte y atributos elásticos derivados para propósitos geomecánicos. El artículo, inicialmente presenta un resumen de diferentes maneras para correlacionar la velocidad de corte por medio de modelos, resultados de investigaciones empíricas y de aproximaciones de registros de pozo. Además, describe los parámetros geomecánicos y atributos elásticos más importantes que requieren de la cuantificación previa de la velocidad de corte. En este estudio de aprendizaje supervisado, se utilizó el algoritmo de redes neuronales llamado QP ('quick propagation'), de rápido desempeño computacional. Se muestran ejemplos utilizando registros geofísicos convencionales como rayos gamma, sónico y densidad. De acuerdo con la figura 3, para el entrenamiento se utilizó también la velocidad de onda volumétrica, no obstante, ésta se obtiene directamente del registro sónico. Esto significa que en la entrada del entrenamiento hay datos "redundantes" y se pensaría que no es necesario. Por supuesto, se requiere también conocer la velocidad de corte en los pozos de entrenamiento para estimar los pesos de la red neuronal que serán utilizados, como predictores, de la velocidad de corte, donde no se tiene dicha información (pozos de prueba). Los resultados obtenidos de la predicción de la velocidad de corte y demás atributos elásticos demuestran buen ajuste. Algunas figuras son de baja calidad.

El último trabajo de esta edición por Medina y Salgado



COMITÉ EDITORIAL 2020-2022

**Raúl del Valle García, Efraín Méndez Hernández**

**Carlos Pozos, Rebeca Sánchez, Francisco Abad, José Tepezano.**

está relacionado con la identificación de facies sísmicas calibradas con datos de pozo para áreas prospectivas en aguas profundas. El trabajo ilustra un ejemplo clásico de "clasificación" dentro de las funciones que tiene la inteligencia artificial. Es decir, a partir del entrenamiento de un conjunto de datos (atributos sísmicos), se determinan primero las clases categóricas existentes, las cuales son acotadas por un análisis de componentes principales que ayuda a definir con mayor ponderación las clases particulares, que en este caso son las "sismofacies". La metodología entonces incorpora estas sismofacies a un modelo de litofacies, mediante el algoritmo de Tau, que contempla el análisis estadístico para establecer las funciones de probabilidad de ocurrencia de las litofacies. Se muestra un ejemplo en aguas profundas donde se utilizan una serie de atributos sísmicos, incluyendo descomposiciones espectrales, para definir de manera supervisada las facies litológicas en un volumen sísmico. Se necesita, además, calibrar la respuesta sísmica con la información petrofísica de pozos. Tanto la propiedad sísmica como los registros de pozos se incorporarán a un modelo geocelular que garantice una mejor resolución horizontal. Las imágenes del trabajo son de gran calidad.



# Contenido

## Tema: Inteligencia Artificial en Geociencias

### Caracterización Sísmica Empleando Algoritmos de Inteligencia Artificial para la Propagación de Propiedades de Roca en el Modelado Estático.

Sergio R. Mata García (Schlumberger), Javier Carrasco Hernández (Jaguar E&P),  
José L. Ortiz López (Jaguar E&P).

8

### Uso de Inteligencia Artificial en la Distribución de Facies Elásticas Relacionadas a el Tren de Compactación de los Yacimientos Clásticos de la Formación de Chicortepec.

Gioconda J. Montilla T. (Emerson), Rubén Charles (Emerson), Cintya Galicia A. (Emerson),  
Abelardo Escamilla. (Petróleos Mexicanos), Felipe Lavariega (Petróleos Mexicanos)

22

### Obtención de la Velocidad de Corte y Parámetros Elásticos - Geomecánicos, Utilizando Redes Neuronales.

Daniel López Aguirre, Candidato a Doctor en Ingeniería, Posgrado de Ingeniería, UNAM,  
Ciudad de México, daniel\_lopeza@comunidad.unam.mx

Silvia Raquel García Benítez, Investigadora del Departamento de Geotecnia, Instituto de Ingeniería,  
UNAM, México, sgab@pumas.iingen.unam.mx

Nicolás López Rubén, Investigador del Instituto Mexicano del Petróleo,  
Ciudad de México, rnlopez@imp.mx

30

### Flujo Tecnológico Aplicado a la Identificación de Facies Sísmicas Calibradas con Información de Pozos en Áreas de Exploración Aguas Profundas.

Edgar Eloy Medina Martínez (Emerson / Paradigm, México)  
Jessica Salgado Mendoza (Emerson / Paradigm, México)

44



# Caracterización Sísmica Empleando Algoritmos de Inteligencia Artificial para la Propagación de Propiedades de Roca en el Modelado Estático

Sergio R. Mata García (Schlumberger), Javier Carrasco Hernández (Jaguar E&P), José L. Ortiz López (Jaguar E&P).

CMP2019\_573  
Artículo presentado  
en el CMP / 2019

## ● Resumen

Este trabajo consiste en mostrar de manera completa cual es el margen de utilidad de los algoritmos de inteligencia artificial para la distribución de propiedades de roca en el modelado estático. Esta metodología consiste en un modelado directo utilizando redes neuronales y algoritmos genéticos para la optimización de patrones de correlación entre trazas sísmicas de volúmenes apilados y propiedades de roca. Una vez obtenida una función de correlación no lineal entre trazas sísmicas y propiedades de roca a nivel de pozo, se estima la respuesta espacial usando el volumen sísmico de estudio. Dicho trabajo de caracterización sísmica es directamente dependiente de la minimización de errores durante la interpretación sísmico estructural (calibración tiempo-profundidad, correlaciones estratigráficas, validación estructural de interpretación, complejidad estructural del modelado). Siendo estos puntos primordiales para lograr una adecuada correlación entre trazas sísmicas y datos de pozo para estimación de propiedades de roca.

El mecanismo conjunto de redes neuronales y algoritmos genéticos estima funciones de correlación no lineales y optimiza los parámetros para minimizar el error del modelado de propiedades de roca a través de datos sísmicos. Esta metodología es aplicada a datos reales, con alta complejidad estructural y gran número de pozos. Los resultados de la caracterización sísmica corresponden a volúmenes sísmicos de propiedades de roca calibradas con información de pozo. Dichos volúmenes de propiedades son empleados inicialmente para la generación de un modelo de facies geológicas. Posteriormente, facies y volúmenes sísmicos son utilizados para la distribución tridimensional de propiedades petrofísicas como: tipo de roca, porosidad, volumen de arcilla y permeabilidad. Así, el uso de los algoritmos de inteligencia artificial puede ser aplicado para la reducción de incertidumbre durante la estimación espacial de propiedades de roca y el cálculo de volúmenes de hidrocarburos.

## Introducción

La estimación espacial de propiedades de roca es fundamental para procesos de caracterización en etapas de exploración, desarrollo y producción de campos petroleros. Los modelos integrados de caracterización pueden ser usados para planeación de nuevos pozos, cálculo volumétrico de hidrocarburos y flujos de trabajo de simulación numérica. La ubicación y densidad de pozos en cada campo es variable y así la caracterización del subsuelo refleja un reto generalizado. La integración de información sísmica 3D, en este proceso, permite tener una representación más acertada de la distribución de propiedades de roca en el subsuelo (Doyen, 2007).

Existen métodos conocidos para la caracterización sísmica del subsuelo usando datos sísmicos apilados: "coloured inversion" (Lancaster and Whitcombe, 2000), "sparse spike inversion" (Ronghe and Surarat, 2002), inversión estocástica (Haas and Dubrule, 1994), entre otros. Veeken et al. (2009) presentan una solución alternativa para estimar propiedades de roca a través de datos sísmicos apilados, con base en un esquema de redes neuronales y algoritmos genéticos. La solución conjunta permite correlacionar trazas sísmicas con propiedades de roca de pozo, inicialmente en la vecindad de los pozos y, una vez calibrada, se estima la propiedad de roca en el volumen sísmico. Lo anterior se logra usando un operador no lineal y una serie de pesos, los cuales son optimizados a través de los algoritmos de inteligencia artificial.

Plantear una función no lineal de correlación entre trazas y propiedades de roca, es posible a través de la correcta selección de información y su acondicionamiento. Las propiedades de roca que pueden ser correlacionadas con las trazas sísmicas, serán aquellas que tienen una correspondencia directa sobre el fenómeno de propagación de una onda elástica en el subsuelo (impedancia acústica, densidad, litología, velocidad de onda, módulos elásticos, porosidad, saturación de fluidos, entre otras). Además, es necesaria



la caracterización del dato sísmico a usar (calidad de imagen, contenido de frecuencias y amplitudes, frecuencia dominante, resolución), para acotar la ventana de análisis donde los resultados serán confiables. Así también los datos de pozo deben de ser acondicionados en un rango de frecuencias equiparable con la información sísmica.

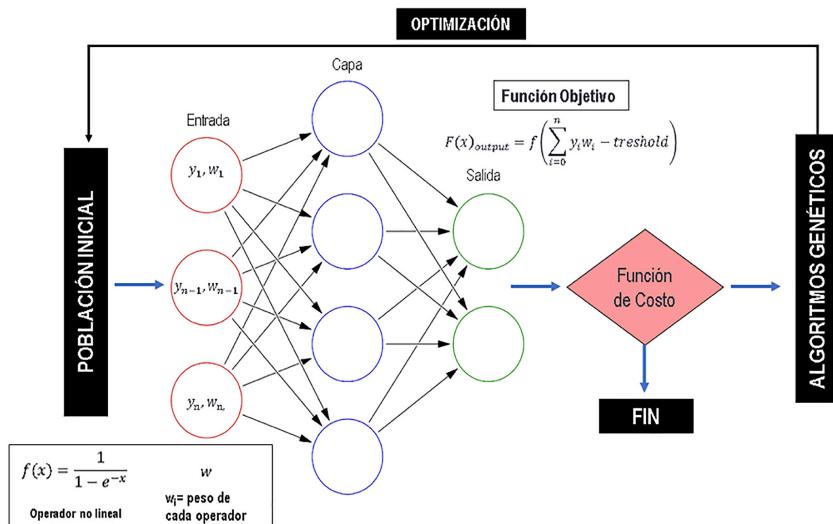
El caso de estudio está ubicado en una zona de alta complejidad estructural, con 70 pozos utilizados para la calibración y con baja continuidad de reflectores sísmicos, debido a variaciones laterales y verticales litológicas. No obstante, a través de un proceso detallado de interpretación sísmico estructural y acondicionamiento de la información sísmica y de pozo, se logra la estimación de propiedades de roca en el subsuelo con el uso del dato sísmico. Las propiedades estimadas corresponden a porosidad y volumen de arcilla, ambos cubos sísmicos de propiedades son utilizados posteriormente en la generación de un modelo de facies, tipo de roca, porosidad, volumen de arcilla y permeabilidad. Las propiedades finales son calibradas con información de pozo, análisis geoestadístico y funciones de correlación.

### Algoritmos de Inteligencia Artificial

Las redes neuronales (McCulloch y Pitts, 1943) y los algoritmos genéticos (Holland, 1992), son parte de un grupo de algoritmos de

inteligencia artificial desarrollados durante la segunda mitad del siglo XX, para apoyar la solución de problemas complejos de ingeniería y ciencia. Los algoritmos genéticos trabajan a partir de conceptos de evolución biológica, tales como selección, crusa y mutación, para lograr una optimización global de la solución (Smith et al.1992).

Para el escenario de resolver el problema de no linealidad de correlación entre datos sísmicos y propiedades de roca de pozo, las redes neuronales seleccionan la mejor combinación de operadores no lineales a utilizar, mientras los algoritmos genéticos optimizan los pesos ( $w$ ), que serán aplicados en cada iteración (Veeken et al., 2009). La figura 1 muestra de manera general cual es la metodología de modelado usando esta aproximación. A través del aprendizaje intrínseco de la solución se determina la función objetivo  $F(x)$ , que será conformada de una suma finita de operadores no lineales y pesos. La diferencia entre  $F(x)$  y la propiedad de roca en el pozo es evaluada con la función de costo (error medio cuadrático de la aproximación). Si el error no está dentro de la tolerancia aceptable, se genera una nueva población de elementos a través de los algoritmos genéticos (selección, crusa y mutación). Esta nueva generación de elementos es ingresada al proceso de redes neuronales otra vez. Este procedimiento es iterativo hasta alcanzar el error mínimo requerido. Con la respuesta calibrada a nivel de pozo se utilizará la función objetivo  $F(x)$ , para estimar la propiedad de roca en el volumen sísmico.



**Figura 1. Esquema de solución conjunta de redes neuronales y algoritmos genéticos para aproximar la propiedad de roca a partir de las trazas sísmicas.**

Las propiedades de roca estimadas pueden ser utilizadas para generar guías sísmicas mucho más confiables, para distribuir las propiedades petrofísicas en la caracterización de yacimientos. Una vez integrados estos cubos sísmicos de propiedades con la información de pozo, se logra obtener una distribución de mayor certidumbre.

### Marco Geológico Regional

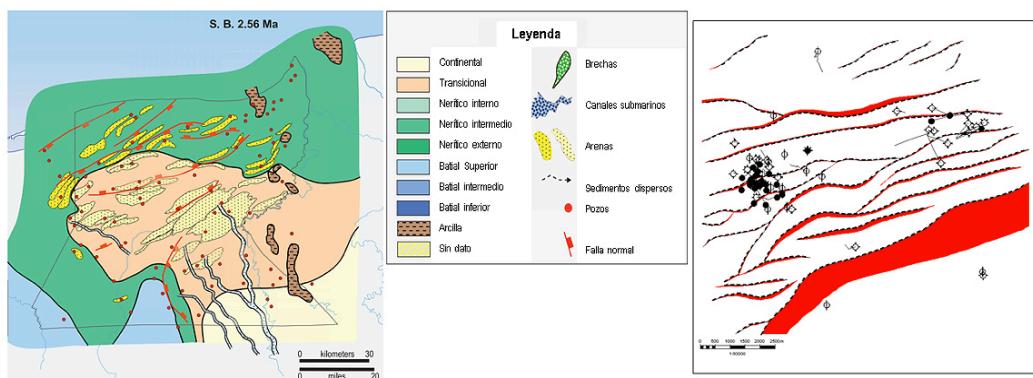
La zona de interés se localiza en la subprovincia geológica denominada la Cuenca de Macuspana. Se encuentra limitada al Este-Noreste por la falla de Macuspana que separa a la Plataforma de Yucatán, al Oeste-Noreste por la falla Frontera que lo divide del Pilar de Reforma y al Sur por la Sierra de Chiapas. Esta subprovincia geológica es conocida por ser productora de gas no asociado en yacimientos de edad Terciaria compuestos de areniscas fluvio-deltaicas y de plataforma, relacionados con trampas estratigráficas y estructurales (Chavez-Valois et al., 2009). El modelo estructural se caracteriza por un sistema de fallas líticas del Mioceno-Plioceno con dirección Noreste-Suroeste y basculamiento hacia el Noroeste (figura 2).

En el Mioceno, debido a los efectos de la Orogenia Chiapaneca, se formaron anticlinales por inversión de las fallas líticas y estructuras del tipo "roll over". Estos eventos estructurales, asociados a un depósito de progradaciones provenientes de las regiones altas del Sur, conformó que los yacimientos de hidrocarburos estén clasificados por entrampamientos estructurales con un alto componente estratigráfico. El rumbo preferencial del sistema de fallamiento normal tiene una orientación Noreste-Suroeste. La falla normal principal es de crecimiento con vergencia hacia el Noroeste. Esto ocasiona amplias superficies de despegue, provocando grandes deslizamientos de bloques estructurales

escalonados, limitados al Norte por fallas líticas. Este deslizamiento de bloques escalonados hacia el Noroeste provoca la formación de fallas normales reactivas con movimiento inverso. Esto causa que en la parte central de los bloques deslizados se forme una estructura del tipo "straddle", es decir, un graben en lo alto de la estructura provocada por un colapso gravitacional, incluyendo un relleno de sedimentación que oculta la estructura.

Durante el Oligoceno-Plioceno, en la Cuenca de Macuspana, se depositaron sedimentos lutíticos profundos, mientras que para el Oligoceno-Mioceno se desarrollaron depósitos de aguas someras. Para el Mioceno-Plioceno se formaron una serie de sistemas deltaicos dominados por oleaje con progradaciones al Noroeste, lo cual permitió el desarrollo de zonas clave para la acumulación de hidrocarburos (Morán-Zenteno et al., 1994). El sistema deltaico influenciado por oleaje construye cuerpos de arenas discontinuos en forma de espiga bidireccionales y en el sector de prodelta se crean cuerpos de arena alargados en la planicie de marea baja (figura 2). Se identificaron tres facies de un sistema deltaico: planicie deltaica, frente deltaico y prodelta.

La roca generadora se caracteriza por lutitas del Mioceno Inferior ricas en gas y condensado. La roca almacenadora está distribuida en depósitos de planicie deltaica, sistema de canales amalgamados, abanicos submarinos y facies de barras deltaicas. El sello está conformado por secuencias de lutitas y arcillas depositados entre paquetes de arenisca de espesores no mayores a 100 metros. El sistema de trampas de hidrocarburos está asociado a la componente estructural con cierres en cuatro direcciones. El componente estratigráfico se relaciona con depósitos de areniscas acuñándose contra plegamientos.



**Figura 2. Lado izquierdo, modelo tectónico-sedimentario regional de la zona durante el Plioceno (Chavez-Valois et al., 2009). Lado derecho, marco estructural local con pozos y fallamiento normal (fallas rojo).**

## Información Sísmica y de Pozo

El área de estudio tiene una superficie aproximada de 100 km<sup>2</sup>. Se contemplaron alrededor de 70 pozos, de los cuales 20 tienen núcleos y 14 con información paleontológica. Los registros geofísicos usados para la correlación estratigráfica tienen las curvas: Potencial Espontáneo (SP), Rayos Gamma (GR), Resistividad (RD, AT90), Sónicos (DT) y Densidad (RHOB). Se correlacionaron los topes y bases formacionales desde el Reciente hasta el Oligoceno, a través de identificación de patrones eléctricos representativos y columna geológica completa, para la selección de los pozos tipo. El trabajo anterior se validó con secciones estructurales sísmicas para la integración del modelo geológico.

El volumen sísmico de trabajo tiene un procesamiento de migración después del apilamiento, sin filtro y sin ganancia con una buena preservación de amplitudes. Tiene un nivel bajo de efectos de difracciones, producto de una buena migración. La resolución vertical sísmica permite distinguir cuerpos de arena de espesor entre

40-60m. Por lo tanto, la información sísmica cumple con una calidad óptima para fines de interpretación sísmica.

## Correlación Estratigráfica

Las arenas de interés económico se encuentran clasificadas en parte superior e inferior. Estas arenas se dividen por un sello de aproximadamente 50 metros. La respuesta del patrón del potencial espontáneo (SP), muestra una arena superior de tipo transgresiva tratándose de una arena marina con alto contenido de arenas. La arena basal presenta un patrón SP correspondiente a una arena regresiva de tipo continental. Esta secuencia estratigráfica se encuentra correlacionada en toda el área de interés. Se identificaron patrones eléctricos para 5 lito-tipos: planicie deltaica, frente deltaico, planicie de inundación, canales y prodelta. La figura 3 muestra una línea de correlación estratigráfica SW-NE. Los elementos descriptivos de ambientes sedimentarios se encuentran discretizados para relacionarlos con los tipos de roca estimados por petrofísica.

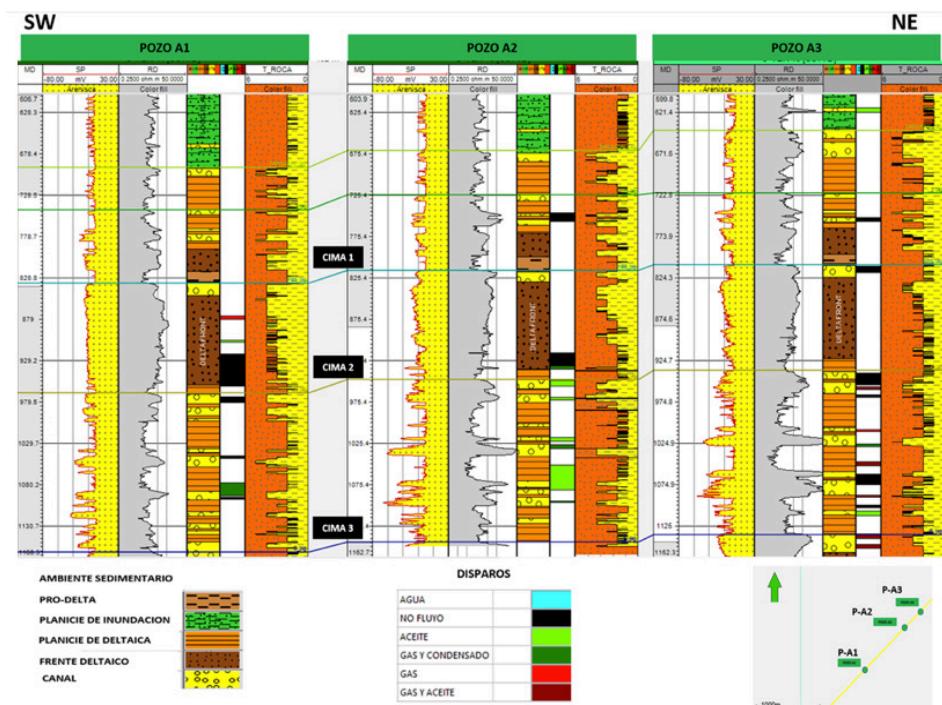


Figura 3. Línea de correlación estratigráfica SW-NE. Los elementos descriptivos de ambientes sedimentarios se encuentran ya discretizados para relacionarlos con los tipos de roca estimados por petrofísica.

## Interpretación Sísmico Estructural

La interpretación sísmica, dentro de un proceso de caracterización sísmica, es un factor elemental para correlacionar adecuadamente la respuesta sísmica con las propiedades de roca de pozo. Se requiere una minuciosa calibración de los sismogramas sintéticos para el inicio de la interpretación sísmica y la construcción del modelo de velocidades. A través de la minimización de los posibles errores en esta etapa, se pueden correlacionar correctamente las trazas sísmicas con las propiedades de roca. Para esto se requiere de un proceso iterativo de calibración que más adelante se detallará.

**Calibración Sísmica - Pozo.** Se ejecutó un trabajo de acondicionamiento de registros para 70 pozos. La selección de los pozos para sismogramas sintéticos fue de acuerdo con: 1) Completitud de los registros en columna perforada. 2) Disponibilidad de checkshots o VSPs (perfiles sísmicos verticales). 3) Ubicación dentro de estructura

compartamentalizada. 4) Penetración total del pozo. La selección final para ejecutar la calibración tiempo profundidad considera 11 pozos. Previo a los sismogramas sintéticos finales, se ejecutó edición y reconstrucción de curvas (densidad y sónico), y calibración de registros sínicos con VSP o Checkshot. Se tienen 5 cimas formacionales de interés, usadas para la elaboración de los sismogramas sintéticos. La figura 4 muestra las velocidades de intervalo finales de la calibración tiempo-profundidad y los plays estudiados (naranja, verde, morado y amarillo). Las primeras tres zonas son consideradas como un intervalo sísmico (I1) por contenido de frecuencia similar, frecuencia dominante 16 Hz y resolución sísmica de 40m. El segundo intervalo (I2) con una frecuencia dominante de 12Hz y resolución sísmica de 60m. Las ondículas teóricas utilizadas son tipo Ricker, previamente se ejecutó una extracción determinística de las mismas. Los sismogramas sintéticos fueron ejecutados con ondícula variable en tiempo. Este estudio de caracterización sísmica es ejecutado solamente en el intervalo I1.

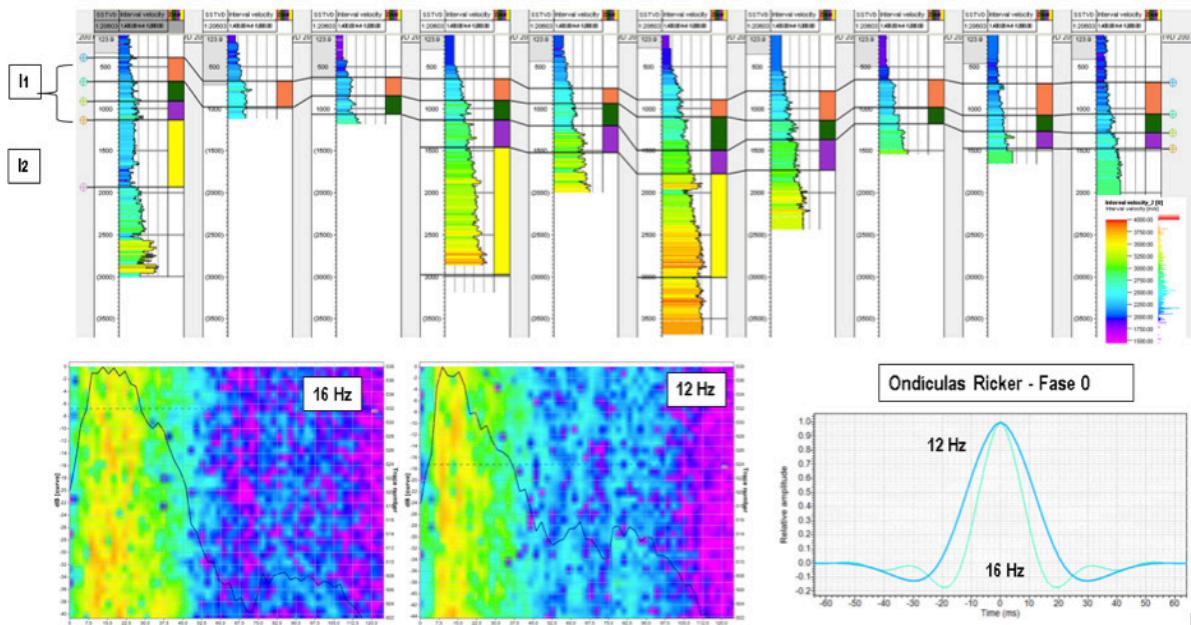


Figura 4. Arriba, velocidades de pozo finales utilizadas para la relación tiempo profundidad de 11 pozos para interpretación. Abajo, contenido de frecuencia de los dos intervalos y ondículas teóricas utilizadas.

**Interpretación Sísmica.** Se tiene una estructura en flor negativa, debido a un margen extensivo con fallas lístricas acompañado de movilidad de arcillas en los niveles inferiores. La falla lístrica de este bloque se encuentra ubicada en el sur de la estructura, al noroeste de la falla lístrica predominan una serie de fallas de crecimiento que forman un anticlinal en la parte central, debido al empuje inferior de la arcilla (figura 5). Estos elementos generan una alta compartmentalización en el bloque. A través de correlaciones estratigráficas y las relaciones tiempo profundidad de los once pozos, se ejecutó la interpretación de 23 fallas y 5 horizontes.

**Modelo Sólido.** Preservando la complejidad estructural del bloque, se incluyeron todas las fallas y horizontes interpretados, lo cual es primordial para el modelo de velocidades y la calibración de atributos sísmicos tridimensionales. El modelo estructural va desde el nivel de referencia 0ms hasta 3600 ms. La figura 6, muestra que el carácter estructural original de la interpretación sísmica es conservado durante el modelado de fallas y horizontes. La falla lístrica principal (roja) y el sistema de fallas secundarias determinan la formación de compartimentos. Se observa la posición de los pozos para sismogramas sintéticos en compartimentos independientes.

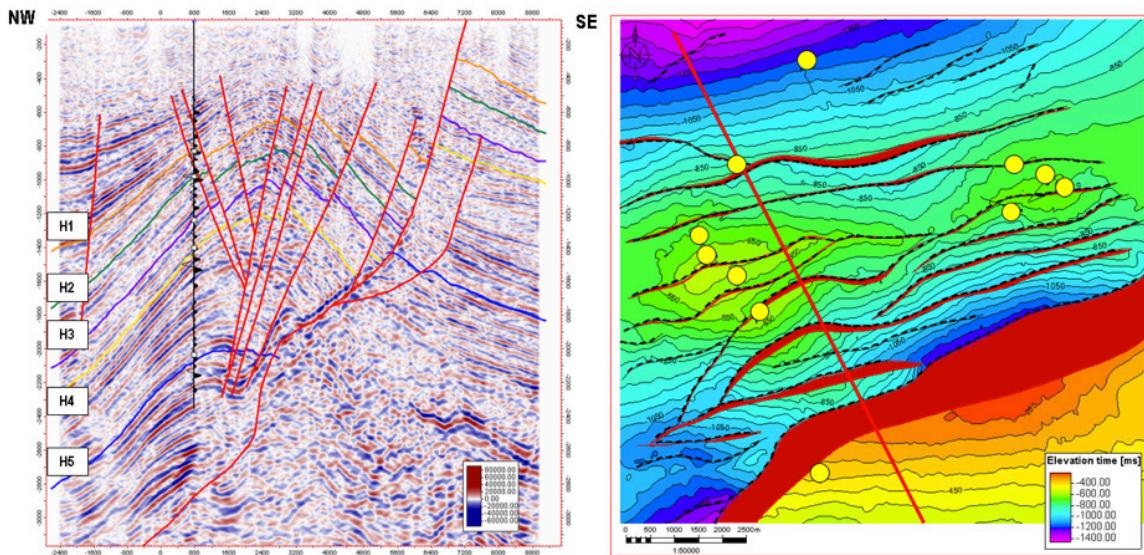


Figura 5. Lado izquierdo, corte de estructura en flor negativa, sistema de fallas (rojo) y horizontes interpretados (L1, L2, L3 y L4). Lado derecho, mapa en tiempo del nivel superior con la ubicación de sismogramas sintéticos (amarillo).

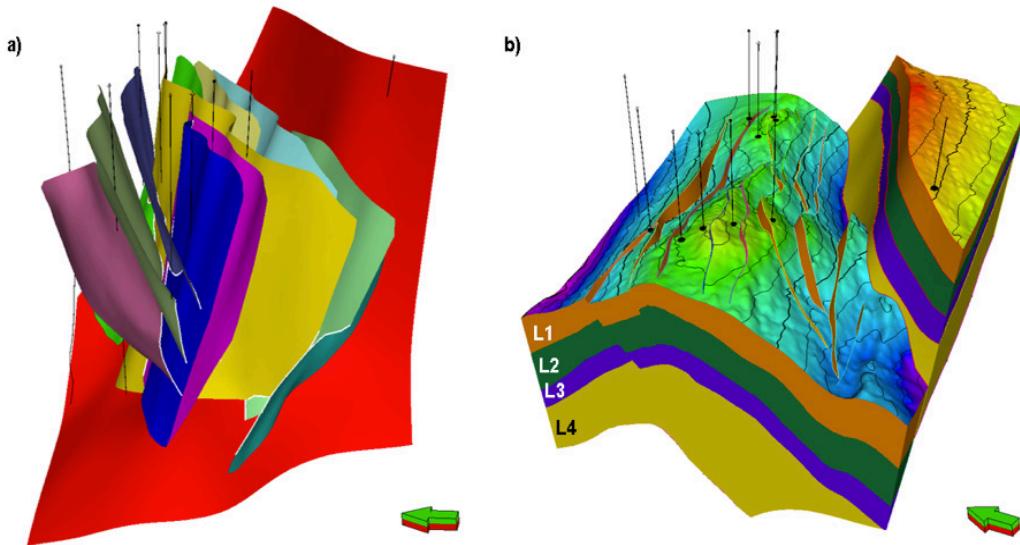
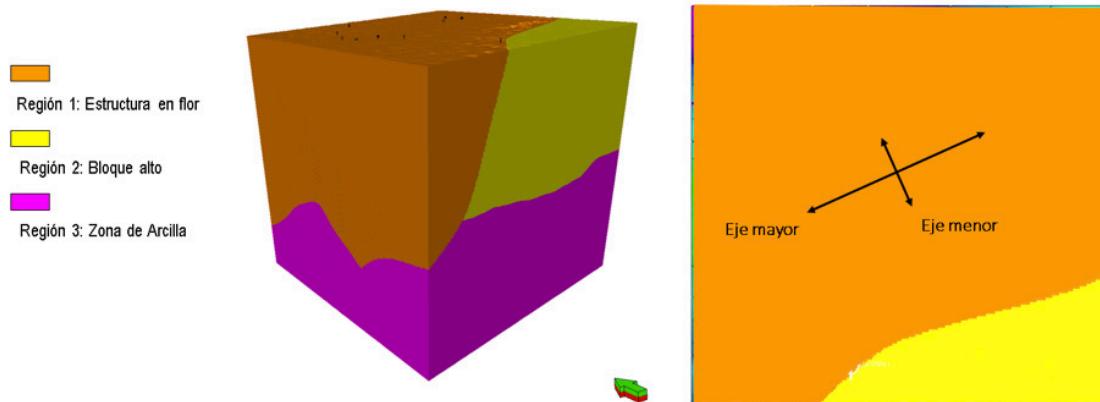


Figura 6. Lado izquierdo, modelo de fallas en tiempo. Lado derecho, integración de horizontes al modelo estructural.

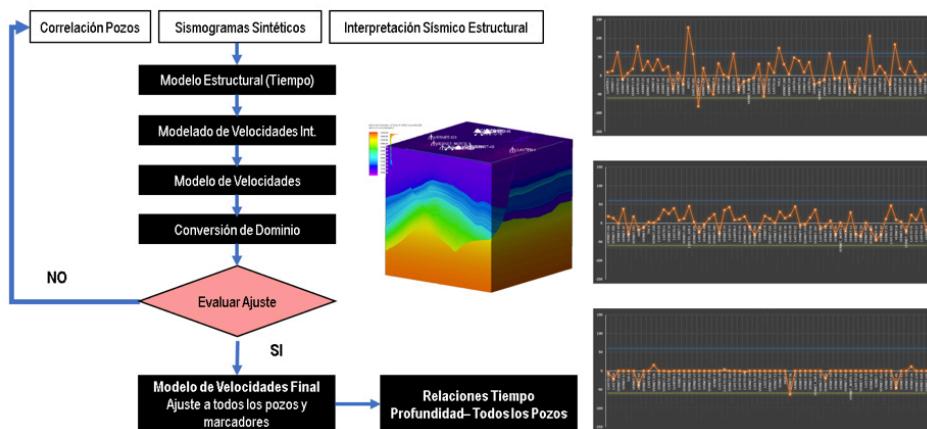
## Modelo de Velocidades

La construcción del modelo de velocidades usa el modelo sólido en tiempo para remuestrear las velocidades de intervalo. Se utilizaron tendencias regionales de velocidad para crear un cubo de velocidades de fondo. El modelo de velocidades se dividió en tres regiones: Región 1: Agrupación de pozos (10) con TDR en la estructura en flor. Región 2: Bloque alto con un pozo perforado, presenta una tendencia de velocidad regional distinta, debido a la tasa de compactación y la nula acción de la arcilla. Región 3: Zona de arcilla, ubicada por debajo de los niveles de interés y modelada con una tendencia regional de velocidad. De esta forma, la distribución de velocidades considera factores geológicos y estructurales (figura 7).



**Figura 7.** Regiones de velocidad utilizadas para aislar la distribución de velocidades de intervalo y dirección de ejes en el análisis variográfico.

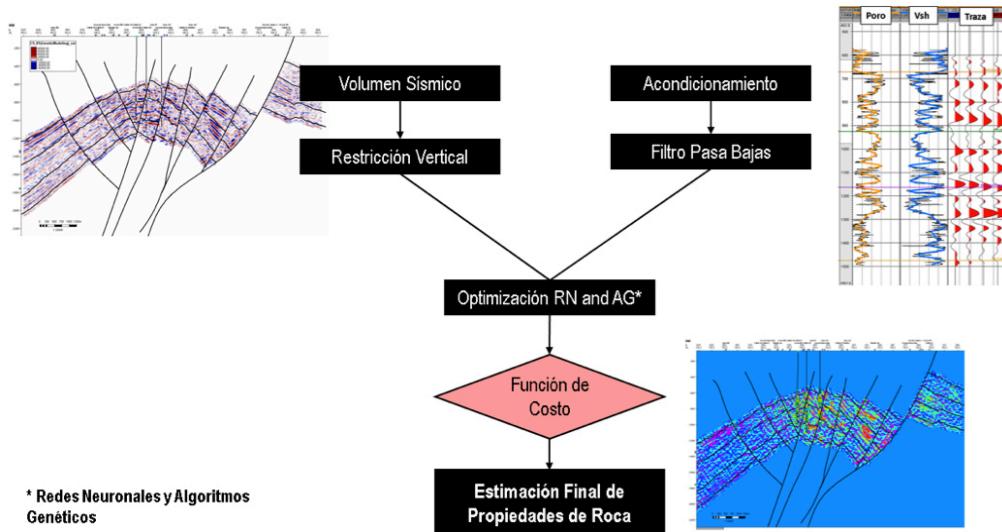
**Conversión de Dominio.** Se considera como un proceso iterativo debido que se necesita la correcta calibración tiempo profundidad para los 70 pozos. La primera iteración del modelo de velocidades y la conversión de elementos debe de ser evaluada con respecto al error que existe para cada cima en cada pozo. Lo tolerancia aceptable para cada intervalo es de +1.5 veces la resolución sísmica. El error de ajuste puede provenir de varias fuentes: 1) Incorrecta interpretación del reflector dentro de un compartimento sin sismograma sintético. 2) Correlaciones estratigráficas. 3) Ajuste de velocidades en sismograma sintético. 4) Complejidad estructural, pozos que atraviesan varias zonas de falla. Al corregir de forma iterativa por cada uno de estos elementos, se logra disminuir el error de ajuste en cada pozo dentro del límite de tolerancia. La figura 8 muestra el proceso iterativo de calibración hasta obtener las relaciones tiempo profundidad finales para los 70 pozos. Del lado derecho se tiene: 1) Error inicial para el primer nivel interpretado. 2) Error después de corrección por elementos descritos. 3) Residual final con ajuste del modelo de velocidades.



**Figura 8.** Lado izquierdo, proceso iterativo de ajuste del modelo de velocidades. Lado derecho, evolución del error al corregir de manera iterativa.

## Acondicionamiento de Datos

La calibración de las trazas sísmicas con propiedades de roca requiere de acondicionamiento previo de la información. Es necesaria la obtención de las relaciones tiempo profundidad para los 70 pozos, ya que el análisis se ejecuta en tiempo. Los pasos de acondicionamiento (figura 9) se describen a continuación. 1) Selección de atributos sísmicos para correlación. 2) Selección de registros (densidad, porosidad, impedancia acústica, volumen de arcilla) para correlación. 3) Diseño de filtro pasabajas para registros de pozo (contenido de frecuencias temporales en intervalo de interés). 4) Restricción vertical del dato sísmico para calibración de trazas sísmicas y propiedades de pozo en esa ventana. Esta información es ingresada al proceso de optimización con algoritmos de inteligencia artificial para minimizar la función de costo y estimar la función objetivo que se aplicará en la correlación de trazas sísmicas con propiedades de roca (figura 9).



## Resultados – Cubos Sísmicos de Propiedades

La evaluación cuantitativa del error global de la solución (función de costo), debe de ser considerada para la selección del mejor par (sísmica – propiedad de roca) en cada escenario. Los mejores resultados se obtuvieron a través de correlacionar volumen de arcilla y porosidad con el cubo de amplitudes originales sin filtro y sin ganancia. La selección de estos dos pares es ingresada al proceso de modelado de propiedades de roca para la calibración inicial en la vecindad del pozo y la posterior estimación de estas propiedades en el subvolumen sísmico.

El resultado final son los volúmenes sísmicos en tiempo de las propiedades de porosidad y volumen de arcilla, calibrados a la información de los 70 pozos en estudio (figura 10). El volumen de arcilla muestra valores bajos para las zonas cercanas a la falla lístrica y en el centro de la estructura, mientras que hacia el norte se incrementa considerablemente, lo que está directamente correlacionado con el modelo conceptual sedimentario (figura 10d). Del mismo modo, la porosidad muestra valores altos en las cercanías de la falla lístrica y en centro de la estructura, mientras sus valores disminuyen hacia la zona de mayor arcillosidad al norte (figura 10b). Estos volúmenes de propiedades son convertidos a profundidad para ser remuestreados dentro de un modelo geocelular.

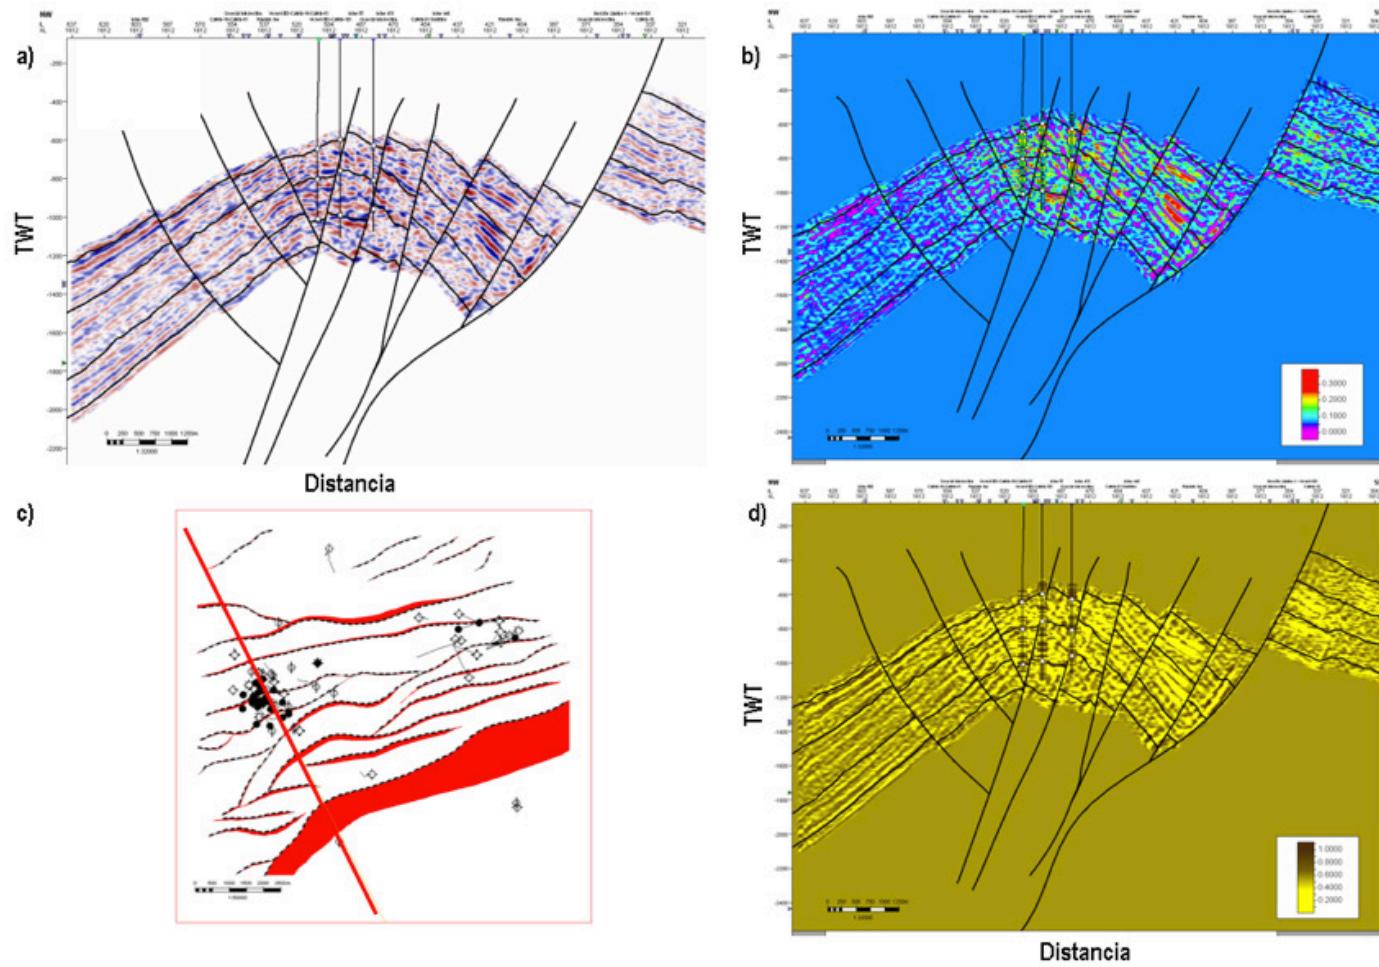


Figura 10. a) Volumen sísmico sin filtro y sin ganancia. b) Propiedad de porosidad calibrada a información de pozo. c) Mapa base de las secciones. d) Propiedad de volumen de arcilla calibrada a información de pozo.

## Distribución de Propiedades de Roca en el Modelo Estático

Las primeras propiedades que deben de ser estimadas dentro de este flujo de trabajo son las propiedades discretas (facies y tipo de roca), que condicionarán cómo será la distribución posterior de otras propiedades (porosidad, volumen de arcilla, permeabilidad).

**Modelo de Facies.** Las facies fluvio-deltaicas interpretadas a nivel de pozo (delta, prodelta, planicie deltaica y canales), son aquellas que deben ser modeladas dentro del intervalo de estudio usando los cubos sísmicos de propiedades como guía principal. Ambos cubos sísmicos de propiedades se usan para generar una tendencia calibrada de volumen de arcilla, que

también considera las variaciones verticales de la información de pozo. Las facies escaladas al modelo estático son estudiadas independientemente para su comportamiento estadístico y su información variográfica. Con la tendencia de volumen de arcilla, facies escaladas al modelo y su análisis geoestadístico, se generan 100 realizaciones equiprobables de modelos de facies. Con estas realizaciones, se estiman volúmenes de probabilidad de ocurrencia para cada facie (figura 11). Los volúmenes de probabilidad por facie geológica son usados para la distribución final de facies (figura 12a).

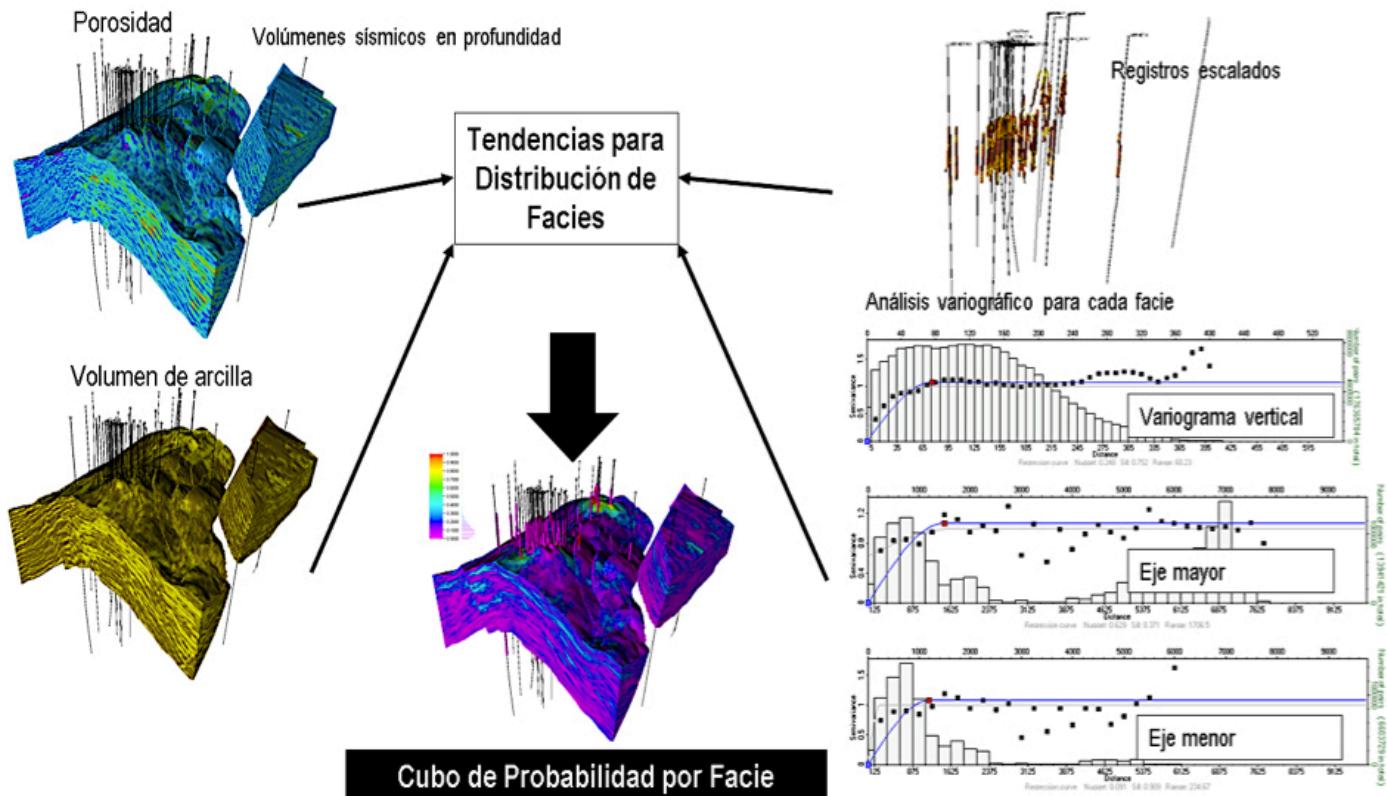


Figura 11. Flujo de trabajo para integración de volúmenes sísmicos de propiedades en la estimación de volúmenes de probabilidad por facie geológica.

**Modelo de Tipo de Roca.** A través de un análisis de laboratorio especial para núcleos (SCAL), se cuantifica la porosidad efectiva y la permeabilidad, para su relación con la garganta poral del sistema. Con los resultados, se usa el Método Winland r35 para clasificar 5 tipos de roca. El tipo de roca 5 es la roca de mejor calidad (alta relación porosidad-permeabilidad), para el flujo de fluidos (facies de arenas). La calidad de flujo va disminuyendo hasta el tipo de roca 1 (facies con alto contenido de arcillas). Cada una de las facies geológicas tiene un porcentaje específico de contenido de tipo de roca, así el estudio de la distribución del tipo de roca va ligado a la distribución previa del modelo de facies. Cada facie se debe usar para analizar estadísticamente el contenido de tipos de roca (figura 12b).

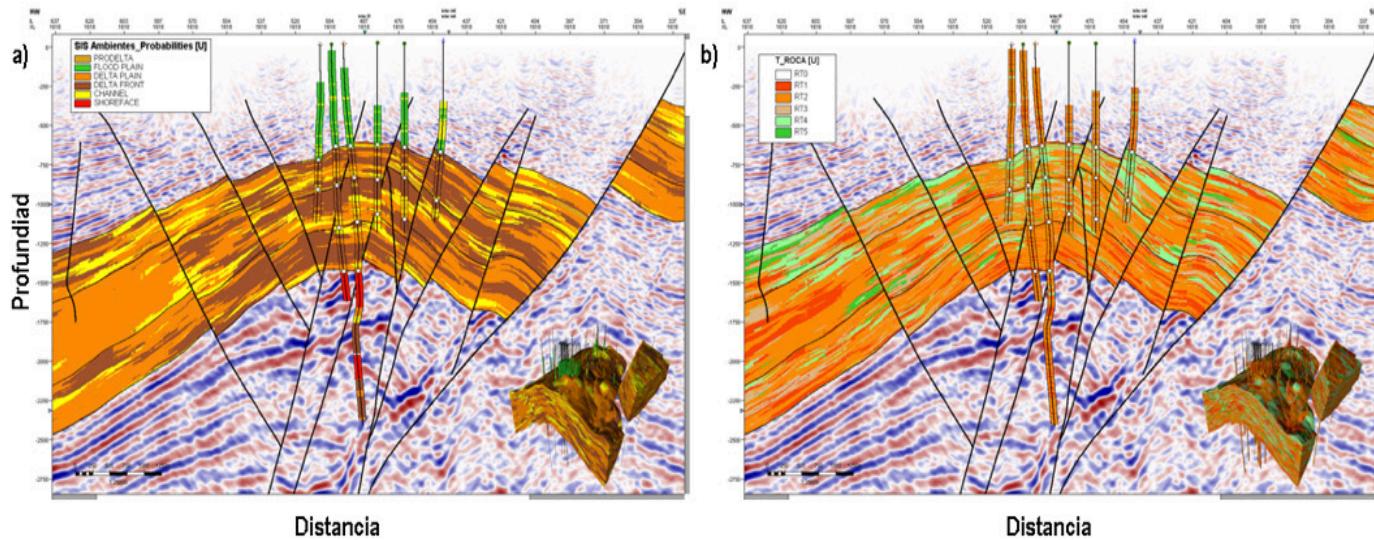
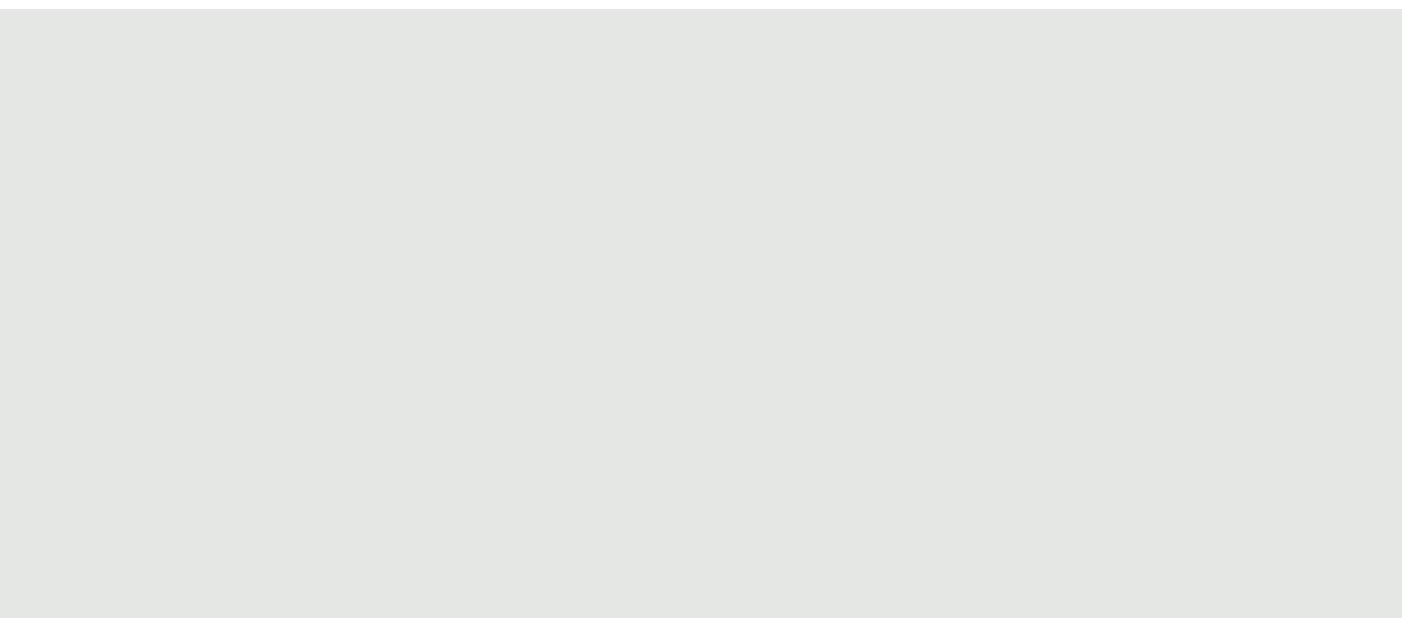


Figura 12. a) Sección estructural con propiedad de facies geológicas. b) Sección estructural con propiedad de tipo de roca.



**Distribución de Propiedades Petrofísicas.** Para la distribución se utilizan los cubos sísmicos de propiedades, las propiedades de facies y tipo de roca, correlaciones intrínsecas entre propiedades y un análisis geoestadístico (figura 13). Porosidad efectiva es la primera propiedad distribuida (figura 14a), posteriormente se liga a ésta la distribución del volumen de arcilla (figura 14c), ambas con un análisis estadístico y variográfico condicionado a cada facie geológica. Finalmente se distribuye la permeabilidad (figura 14b), usando la propiedad de tipo de roca para condicionar el análisis estadístico y variográfico, además se incluye la porosidad como propiedad secundaria (Cokriging). La distribución de la saturación de agua no es parte del alcance de este trabajo; no obstante, tipos de roca, porosidad efectiva y permeabilidad son insumos necesarios para crear funciones de saturación de agua para el modelo.

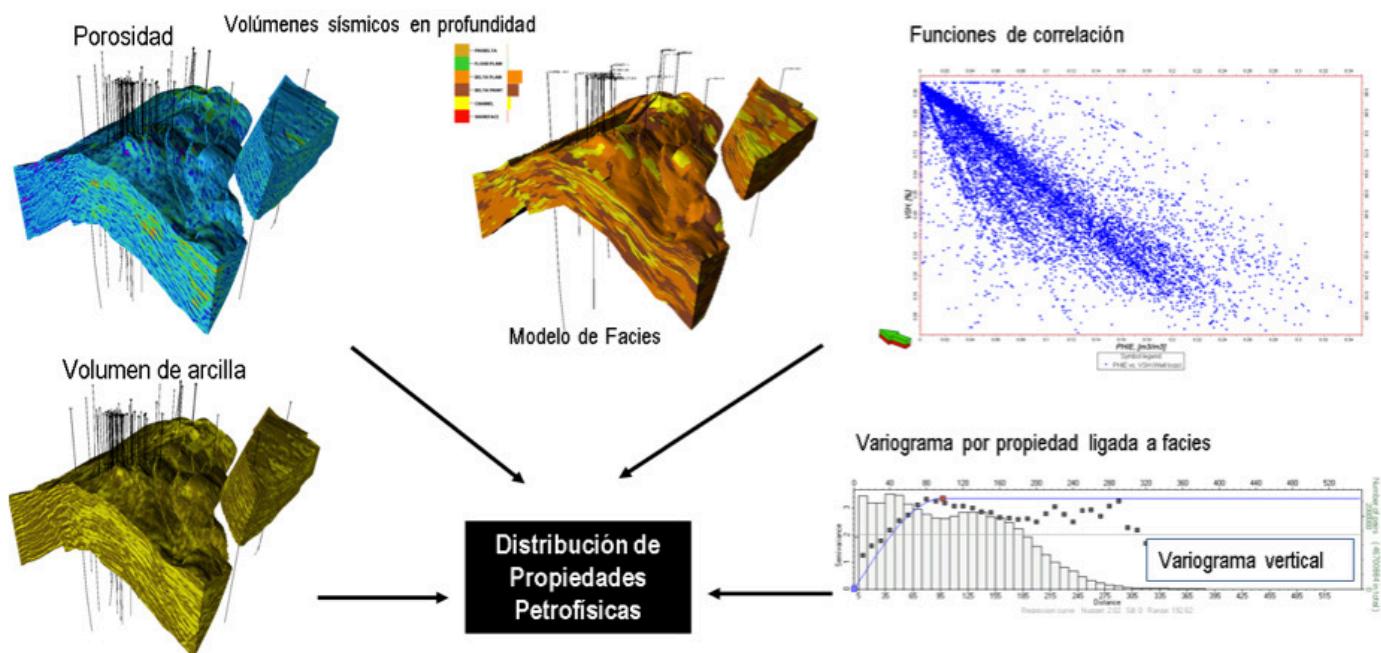
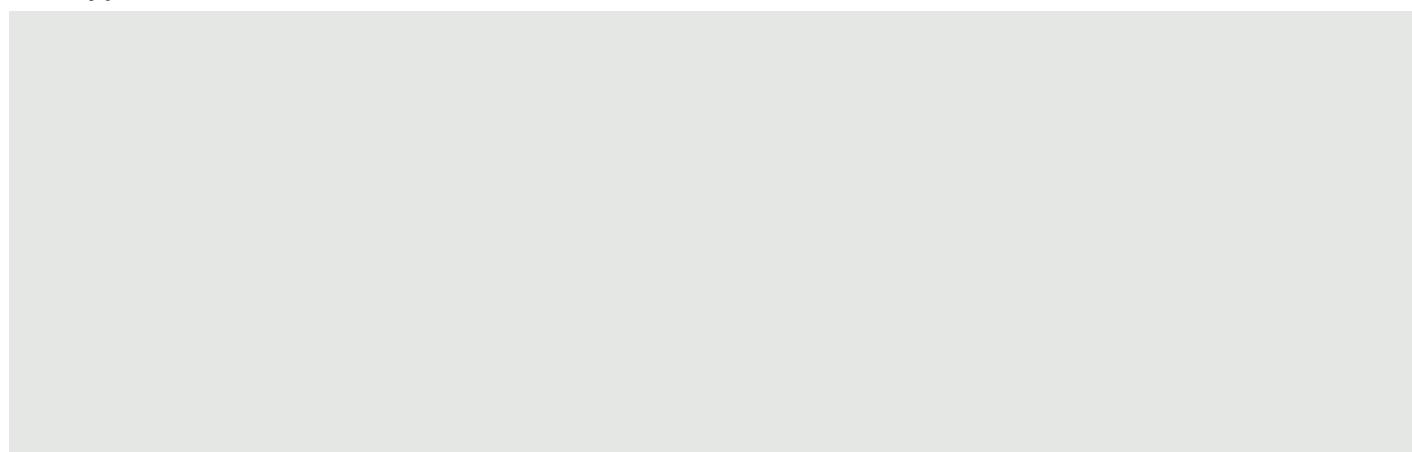
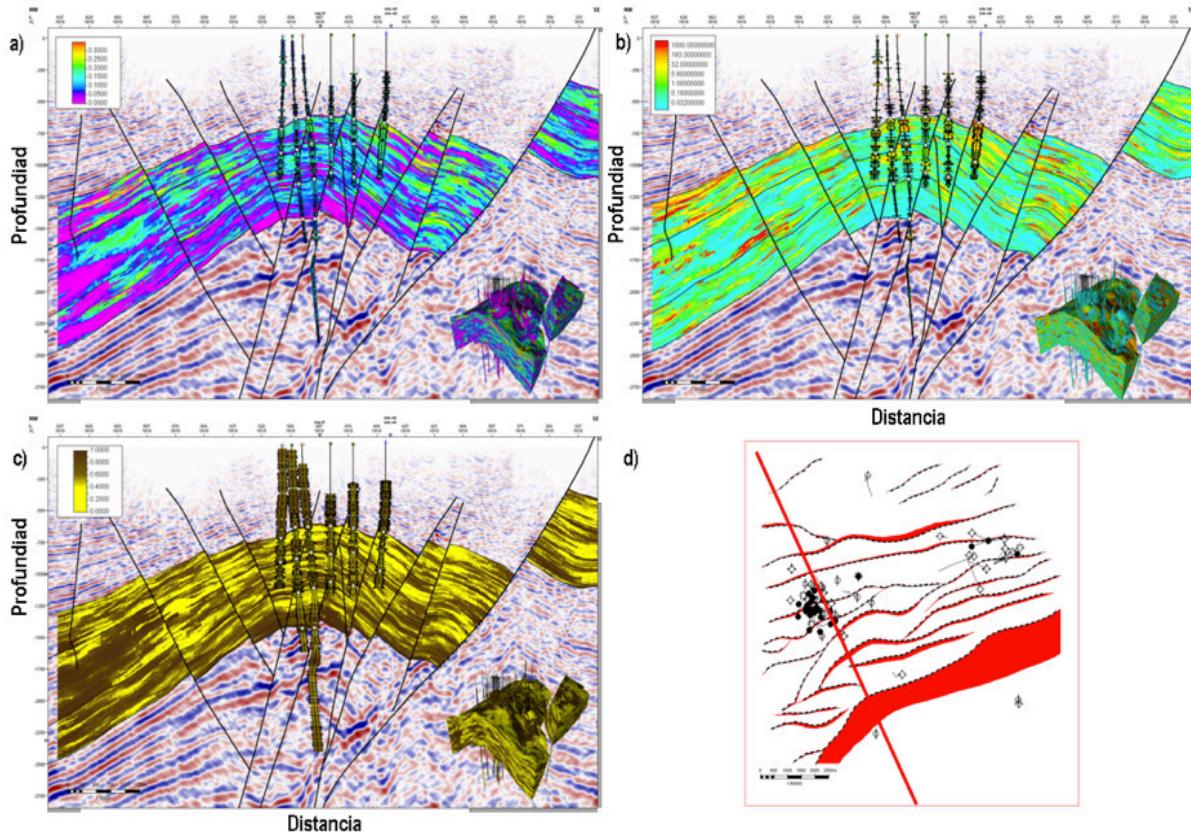


Figura 13. Flujo de trabajo para integración de volúmenes sísmicos de propiedades en la estimación de porosidad efectiva, volumen de arcilla y permeabilidad.





**Figura 14.** a) Sección estructural con propiedad de porosidad efectiva. b) Sección estructural con propiedad de permeabilidad. c) Sección estructural con propiedad de volumen de arcilla. d) Mapa base de las secciones.

### Conclusiones

Se ha demostrado el margen de utilidad de los algoritmos de inteligencia artificial para la caracterización sísmica. Usando la solución conjunta de redes neuronales y algoritmos genéticos, se estimaron correlaciones no lineales entre volúmenes sísmicos apilados y propiedades de roca de pozo. Para alcanzar resultados confiables a través de esta metodología, ha sido primordial la minimización de errores durante la interpretación sísmico estructural y la construcción del modelo de velocidades. Además, se necesita acondicionamiento de la información, tal como restricción vertical de la ventana sísmica de análisis y filtrado pasabajas de los registros. A pesar de la alta complejidad estructural y el elevado número de pozos, se calibró adecuadamente la amplitud sísmica con las propiedades de roca (volumen de arcilla y porosidad) para su estimación espacial.

Los cubos sísmicos de propiedades son integrados en un modelo geocelular en profundidad. La distribución final de propiedades utiliza tendencias sísmicas, análisis geoestadístico de datos de pozo y funciones intrínsecas de correlación entre propiedades. La primera propiedad estimada es el modelo de facies geológicas, posteriormente el tipo de roca es condicionado a las facies. Las propiedades petrofísicas deben de ser condicionadas también a facies o tipo de roca, según correspondan. La distribución final de todas las propiedades logra representar las variaciones verticales y horizontales del modelo sedimentario de facies fluviodeltáticas de depósito de la región. Este trabajo apoyará la estimación volumétrica de los plays estudiados y la generación del plan de desarrollo, para la selección de nuevos pozos a través de un modelo dinámico de simulación.

<b>Nomenclatura</b>	
AG= algoritmos genéticos	
DT= sónico compresional	<b>SCAL=</b> estudio de laboratorio especializado para núcleos
GR= rayos gamma	<b>TDR=</b> relación tiempo profundidad
RHOB= densidad	<b>VSP=</b> perfil sísmico vertical
RN= redes neuronales	w= peso
RD= resistividad profunda	<b>3D=</b> tridimensional
SP= potencial espontáneo	
<b>Agradecimientos</b>	
<p>Agradecemos a Jaguar Exploración y Producción por las facilidades otorgadas en la elaboración del trabajo. A Schlumberger por la implementación de nuevas metodologías y la transferencia de conocimiento. Al Dr. Guillermo Pérez-Cruz por su liderazgo y apoyo para concretar los objetivos del estudio. A Ing. Dalia Ramírez-López, Ing. Mayra Karen-Orsorio y M.C. Carlos Bonifacio-Serralde por ejecutar los flujos de trabajo con eficiencia, parte clave en la terminación del proyecto. Al departamento de Geociencias de Jaguar E&amp;P por colaborar en la integración geológica del área estudiada. A José Martín Rodríguez Betancourt por su apoyo para continuar este estudio de caracterización en niveles más someros de la columna geológica.</p>	
<b>Referencias</b>	
<p>Chávez-Valois, V. M., Valdés, M. d. L. C., Juárez Placencia, J. I., Ortiz, I. A., Jurado, M. M., Yáñez, R. V., Tristán, M. G. and Ghosh, S. 2009, A new multidisciplinary study of tertiary plays in the Southeast Basin, Mexico, in C. Bartolini and J. R. Román Ramos, eds., Petroleum systems in the southern Gulf of Mexico: AAPG Memoir 90, p. 155–190.</p> <p>Doyen, P.M. 2007. Seismic Characterization: An Earth Modelling Perspective. Education Tour Series. Netherlands. EAGE.</p> <p>Haas, A. and Dubrule, O., 1994, Geostatistical inversion – a sequential method of stochastic reservoir modeling constrained by seismic data, first break 12, 561-569.</p> <p>Holland, J. 1975. Adaptation in Natural and Artificial Systems. University of Michigan Press. (Second Edition: MIT Press, 1992).</p> <p>Lancaster, S., and Whitcombe, D. 2000, Fast track "coloured" inversion: 70th Annual International Meeting, SEG, Expanded Abstracts, 1572-1575.</p> <p>McCulloch, W., y Pitts, W. 1943. A Logical Calculus of Ideas Immanent in Nervous Activity. Bulletin of Mathematical Biophysics 5 (4): 115-133. doi:10.1007/BF02478259.</p> <p>Moran-Zenteno, D. J. The Geology of the Mexican Republic. AAPG studies in geology, 0149-1377; no.39, 1994. P. 75 -80.</p> <p>Ronghe, S., and Surarat, K., 2002, Acoustic impedance interpretation for sand distribution adjacent to a rift boundary fault, Suphan basin, Thailand: AAPG Bulletin, 86, 1753-1771.</p> <p>Smith, M. L., Scales, J.A. and Fischer, T.L., 1992, Global search and genetic algorithms. Geophysics: The Leading Edge of Exploration, 22-26.</p> <p>Veeken, P.CH&gt;, Priezzhev, I.I., Shmaryan, L.E., Shteyn, Y.I., Barkov, A.Y., and Ampilov, Y.P., 2009. Nonlinear multitrace genetic inversion applied in seismic data across the Shtokman field, offshore northern Russia. Geophysics vol. 74, no. 6, WCD49-WCD59.</p>	
<b>Trayectoria Profesional</b>	
<p><b>Sergio R. Mata García</b>, Ing. Geofísico egresado de la Facultad de Ingeniería de la UNAM. Maestro en Ciencias por el Instituto de Geofísica de la UNAM, especialidad en sismología y modelación matemática. 10 años de experiencia realizando proyectos de consultoría para caracterización de yacimientos petroleros. Trabajos en interpretación sísmico estructural, modelado de velocidades, caracterización sísmica, modelado complejo de yacimientos y modelado estático. Actualmente trabaja como consultor en Schlumberger y en proyectos de investigación con la UNAM para soluciones numéricas de ecuaciones de flujo con distribución fractal de propiedades.</p> <p><b>Javier Carrasco Hernández</b>, Ing. Geólogo egresado de la Facultad de Ingeniería de la UNAM. Maestro en Ciencias Financieras por la Universidad Autónoma de Barcelona. Maestro en Administración de Empresas (MBA) por la Universidad de Alicante. Tiene 20 años de experiencia en la industria petrolera a nivel nacional e internacional, 18 años trabajando para empresas de servicios como Halliburton-Schlumberger y 2 años para compañías operadoras. Actualmente se encuentra laborando como geólogo senior en la compañía Jaguar E&amp;P, para procesos de caracterización estática.</p> <p><b>José L. Ortiz López</b>, Ing. Geofísico egresado de la Facultad de Ingeniería de la UNAM, 30 años de experiencia en el sector de Gas y Petróleo. Ha participado en actividades desde operaciones técnicas en pozos petroleros, hasta puestos ejecutivos. Dirigió los esfuerzos para la generación de 21 planes de Desarrollo, Evaluación y Continuidad operativa para Jaguar E&amp;P. Profesor de la Facultad de Ingeniería -UNAM y secretario de la SPWLA (Sociedad de Petrofísicos, capítulo México).</p>	

# Uso de Inteligencia Artificial en la Distribución de Facies Elásticas Relacionadas con el Tren de Compactación de los Yacimientos Clásticos de la Formación de Chicontepec

Gioconda J. Montilla T. (Emerson), Rubén Charles (Emerson), Cintya Galicia A. (Emerson), Abelardo Escamilla (Petróleos Mexicanos), Felipe Lavariega (Petróleos Mexicanos)

CMP2018\_156  
Artículo presentado  
en el CMP / 2019

## ● Resumen

Los costos de inversión en la exploración y explotación petrolera se han incrementado conforme a las complejidades de los yacimientos encontrados. Enfocados a la reducción de costos, el avance tecnológico ha dado pasos gigantescos. El tratar de entender el comportamiento de yacimientos complejos de baja porosidad y baja permeabilidad, como es el caso de Chicontepec, convierte a la inteligencia artificial en una tecnología clave y poderosa en la integración de la información de pozos y el dato sísmico.

La problemática del área de estudio está basada en la complejidad de los depósitos clásticos con procesos diagenéticos altamente estratificados con baja porosidad y permeabilidad.

El objetivo principal de este trabajo es la caracterización de este tipo de yacimientos, enfocado en el análisis de la compactación de las arenas y su relación con la calidad de roca almacén que se puede traducir en un incremento de las reservas determinando nuevas áreas prospectivas.

La metodología basada en redes neuronales está enfocada en crear una relación directa entre las facies determinadas en un grupo de pozos y los atributos sísmicos. Se generan modelos probabilísticos que incorporan los pozos y la sísmica. El flujo de trabajo considera la descripción de facies en los pozos definida mediante un análisis de física de rocas, así como la selección del dato sísmico que va a ser usado para la propagación de éstas.

Las propiedades petrofísicas y contenido mineralógico en los intervalos evaluados delimitaron cuatro (4) litofacies, relacionándose a las rocas productivas y validándose con los

intervalos disparados de los pozos con mayor producción acumulada, fueron utilizados los cubos de máxima probabilidad de ocurrencia para obtener su distribución en el área de estudio.

## Introducción

El estudio pretendió estimar el potencial de los recursos prospectivos a través de técnicas avanzadas de inteligencia artificial, asociados a estudios de inversión sísmica elástica y la caracterización de yacimientos para los Campos de Chicontepec.

El área de estudio abarcó diferentes cubos sísmicos (figura 1), los cuales fueron unificados con la finalidad de cubrir las principales asignaciones productoras.

La unión de los cinco cubos permitió realizar una inversión sísmica elástica de 1500 km<sup>2</sup> a nivel del Terciario con el objetivo de:

- Identificar zonas prospectivas asociadas a facies de lóbulos, canales y desborde de canal.
- Identificar zonas afectadas por cementación (zonas compactas).
- Calibrar atributos sísmicos con propiedades petrofísicas (discriminadores).
- Robustecer el modelo sedimentológico.

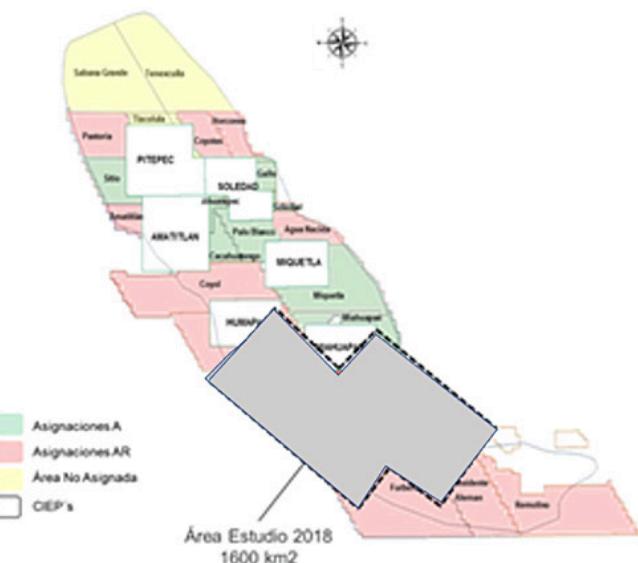


Figura 1. Área de estudio.

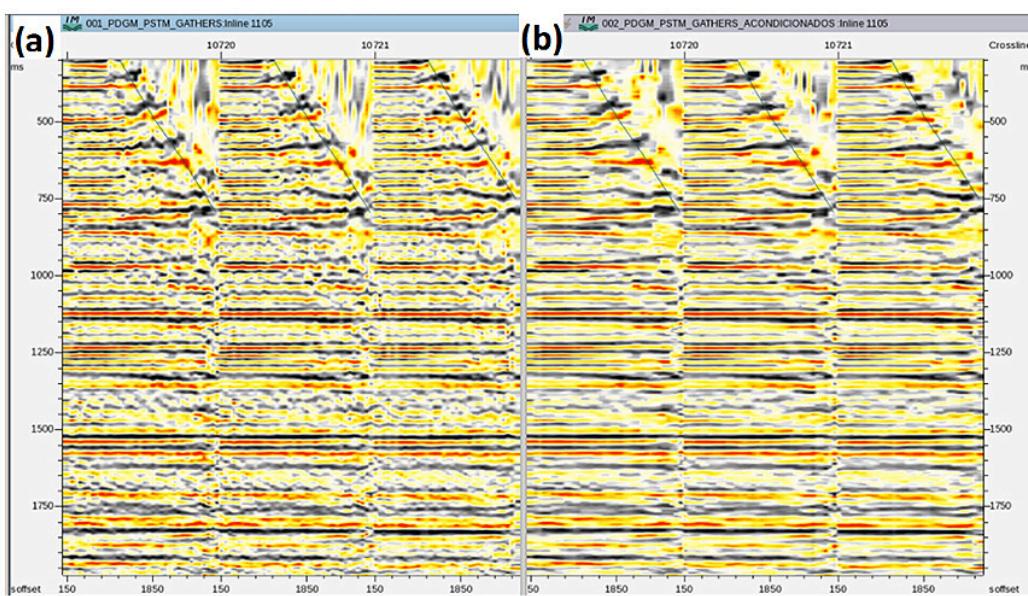


Figura 2. Comparación de los datos sin acondicionamiento (a) y acondicionados (b).

#### Estudios especiales

Los procesos especiales, como la inversión sísmica representan, desde un punto de vista práctico, técnicas que relacionan la imagen sísmica con las variaciones en las constantes elásticas del medio atravesado. Dichas variaciones relacionan parámetros tales como porosidad, litología y contenido de fluidos, clave en la caracterización de yacimientos. La inversión sísmica es un procedimiento que convierte las trazas sísmicas en

#### Desarrollo:

##### Acondicionamiento del dato

El acondicionamiento es una etapa crítica en la caracterización de los datos sísmicos. El análisis de procesos especiales demanda un manejo más riguroso del procesamiento y acondicionamiento de las trazas sísmicas. Son tres los puntos que se deben tratar al realizar el acondicionamiento de los datos pre-apilado:

1.- Mejoramiento de la relación señal-ruido.

2.- Preservación de las frecuencias y amplitudes relativas con respecto al offset.

3.- Alineamiento horizontal de los reflectores primarios en los CRP "Gathers".

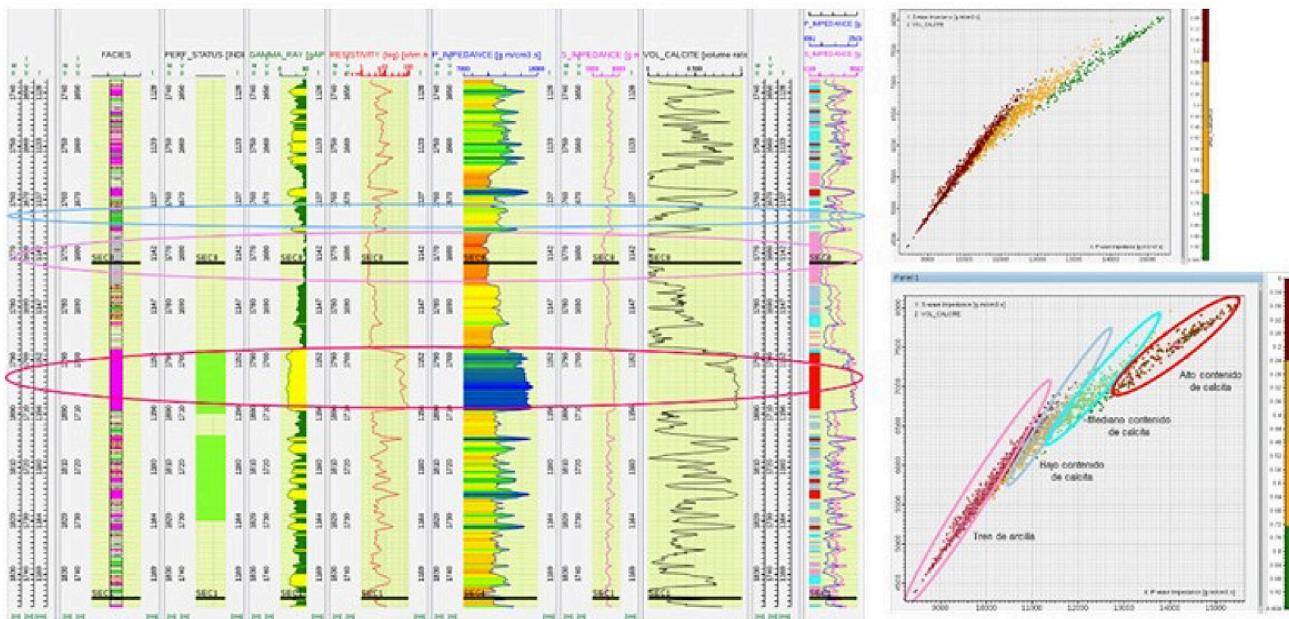
Se aplicó un aplanamiento de los eventos principales a través de un "automatic flattening", el cual se basa en la selección automática de eventos principales en los "gathers", con el fin de aplanarlos.

Para el mejoramiento de la señal-ruido se aplicó un "median filter", el cual realiza un filtro de mediana de todas las muestras de amplitud para un "gather" seleccionado y un tiempo seleccionado. Esto es útil para eliminar puntos atípicos en la dirección de desplazamiento causados, por ejemplo, por múltiples o algún otro ruido. (figura 2).

impedancias. Se basa en el concepto de que la amplitud es proporcional al coeficiente de reflexión y a la reflectividad. Los atributos sísmicos se invierten en atributos de impedancia. Las amplitudes de las trazas sísmicas son transformadas en valores de impedancias acústicas definidas por el producto de la densidad y la velocidad sísmica, parámetros petrofísicos intrínsecos de la roca, por lo tanto, el volumen de datos sísmicos es convertido en un volumen de impedancia acústica, es entonces una herramienta complementaria que permite:

- Detectar heterogeneidades laterales aun cuando no son visibles en los datos sísmicos
- Aumentar la resolución vertical obtenida en la interpretación sísmica convencional
- Correlacionar parámetros petrofísicos con amplitudes sísmicas

Para la calibración de los atributos de la inversión sísmica, se procedió a hacer un análisis detallado de física de rocas, donde se pudo establecer el comportamiento de las propiedades elásticas en los pozos. Las características litológicas y petrofísicas de los intervalos evaluados hacen que los gráficos cruzados entre diferentes propiedades elásticas respondan y tengan coherencia, principalmente, con la litología y con la propiedad de porosidad total. (figura 3).



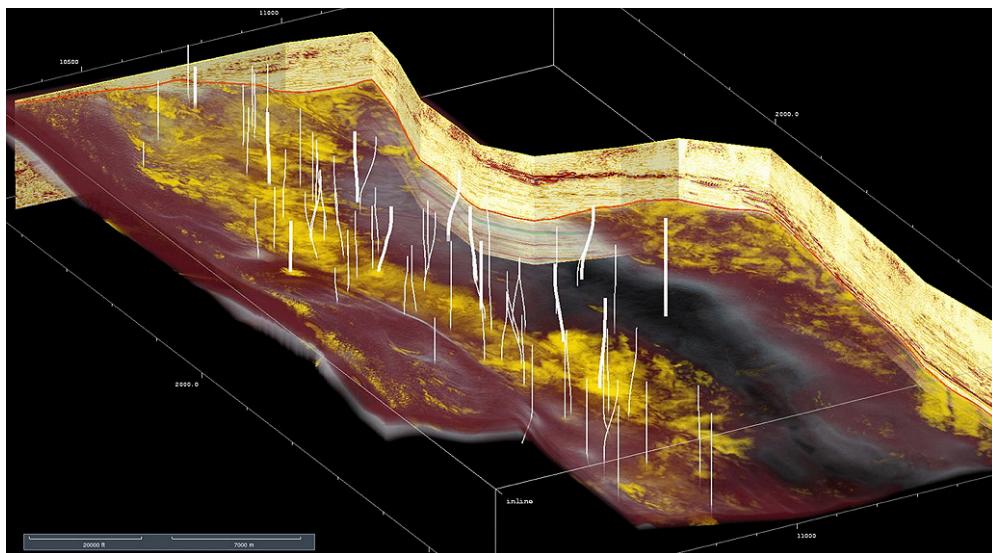
**Figura 3. Gráfico de Impedancia P contra Impedancia S coloreado con el contenido de calcita, mostrando la relación existente entre los valores de impedancia y el contenido de calcita, el trend sombreado en rojo muestra mayor cementación y el trend sombreado en rosado menor cementación.**

Se encontró una relación directamente proporcional entre los valores de impedancia\_p y el porcentaje de calcita en la roca.

Se observó claramente un tren de arcilla para valores bajos (3000-7000 m.g/cm<sup>3</sup>.seg) de impedancia y valores altos de impedancia que corresponden a areniscas con alto contenido de calcita (13000-17000 m.g/cm<sup>3</sup>.seg).

Los atributos de inversión sísmica, calibrados con la información de pozos y el estudio de física de rocas, mostraron que la relación de impedancias permitía una clara discriminación de litología. Se procedió a separar el tren de las lutitas/limolitas seleccionando en él atributos de impedancia, los rangos por encima de impedancia p que sobrepasan los 6000 g.m/cm<sup>3</sup>.seg. De esta manera, se pudo obtener una distribución de las areniscas en la Formación Chicontepec calibrada con los pozos en el área estudiada.

Con el uso de técnicas de visualización, tales como el "Formation Sculping", que permite la extracción de atributos en un intervalo determinado, y aplicando opacidad o transparencia, fueron realizadas geomorfologías correspondientes a lóbulos y canales que enmarcan en el ambiente sedimentario del área (figura 4).



**Figura 4. Distribución de las arenasas, mostrando geomorfologías asociadas a canales y lóbulos de abanicos.**

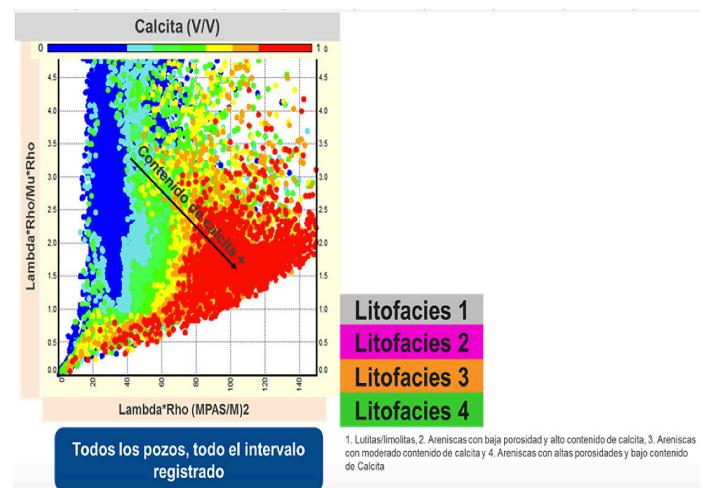
### Distribución de facies elásticas

El objetivo de la metodología de redes neuronales es extrapolación una relación entre los datos sísmicos y la distribución de facies, a partir de su conocimiento en las ubicaciones de los pozos. Esta extrapolación se realiza dentro de un intervalo sísmico. El proceso se puede dividir en cuatro fases principales:

1. Definición del conjunto de datos para el entrenamiento: donde se toman los registros de pozos y los atributos sísmicos. Para el caso estudio los atributos elásticos, previamente analizados en el estudio de física de rocas, mostraron mayor discriminación de las facies usando  $\Lambda^*\rho$  y  $\mu^*\rho$ , los cuales muestran una relación con la compresibilidad y la rigidez respectivamente. Se delimitaron así cuatro (4) facies elásticas: Litofacies 1. Tren de lutitas/limolitas; Litofacies 2. Arenicas con baja porosidad y alto contenido de calcita; Litofacies 3. Arenica con moderado contenido de calcita, y Litofacies 4. Bajo contenido de calcita y mayores porosidades. (Figura 5).

2. Creación de datos a entrenar: Este paso define la relación entre los datos sísmicos y los datos de registro. Se define el intervalo de interés establecido por horizontes correspondientes a la cima y

base de dicho intervalo, (Formación Chicontepec). El entrenamiento se realiza muestreando el registro del pozo de acuerdo con la resolución vertical de la sísmica, obteniendo así valores sísmicos para cada posición y tomando el valor del índice de las facies asociado, en otras palabras, se define un conjunto de entrenamiento.



**Figura 5. Gráfico cruzado de  $\Lambda^*\rho$  contra la relación  $\Lambda^*\rho/\mu^*\rho$  mostrando la discriminación de las cuatro facies elásticas por contenido de calcita.**

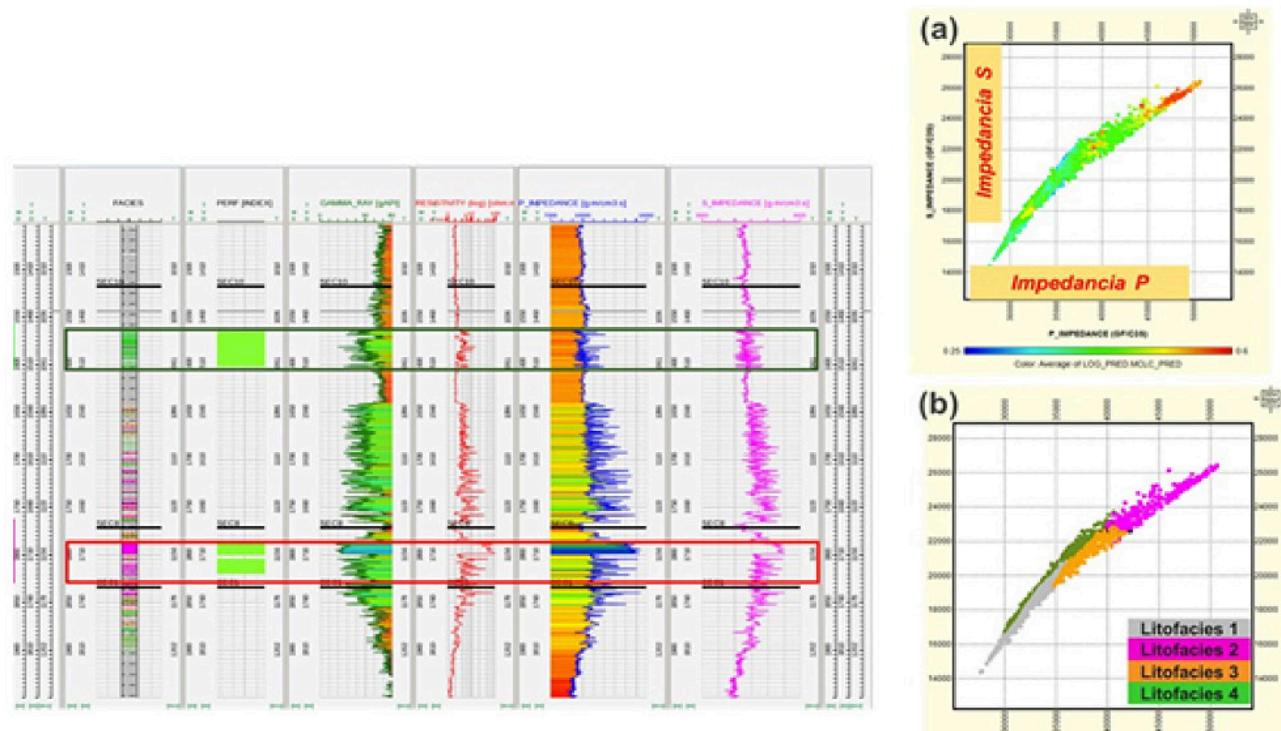
3. Entrenamiento: esta etapa se basa en un algoritmo de cuantificación de vectores de aprendizaje, el cual es un algoritmo de red neuronal artificial que permite elegir la cantidad de muestras de entrenamiento y utiliza un cálculo neural. Dicho método permitió la propagación de las litofacies, creando una relación directa de éstas y los atributos sísmicos.

4. Clasificación: Esta última fase genera modelos probabilísticos que incorporan los pozos y la sísmica, generando un volumen de facies (o mapa o registro), junto con salidas de probabilidad relacionadas. La red neuronal entrenada se usa aquí para estimar las probabilidades para cada facie definida a lo largo de la trayectoria del pozo. Estas estimaciones se basan en la teoría de Bayes. Las probabilidades condicionales se estiman determinando las muestras vecinas más cercanas.

El flujo de trabajo consideró la descripción de facies en los pozos, definida mediante un análisis multimineral y de física de rocas, así como la selección del dato sísmico que va a ser usado para la propagación de éstas. La calibración de las litofacies determinadas con las propiedades elásticas, expresadas en función de las velocidades de onda compresional y de cizalla (obtenidas de los registros sónicos dipolares para los 74 pozos usados en el estudio), junto con la producción los campos dentro del Terciario, mostró que:

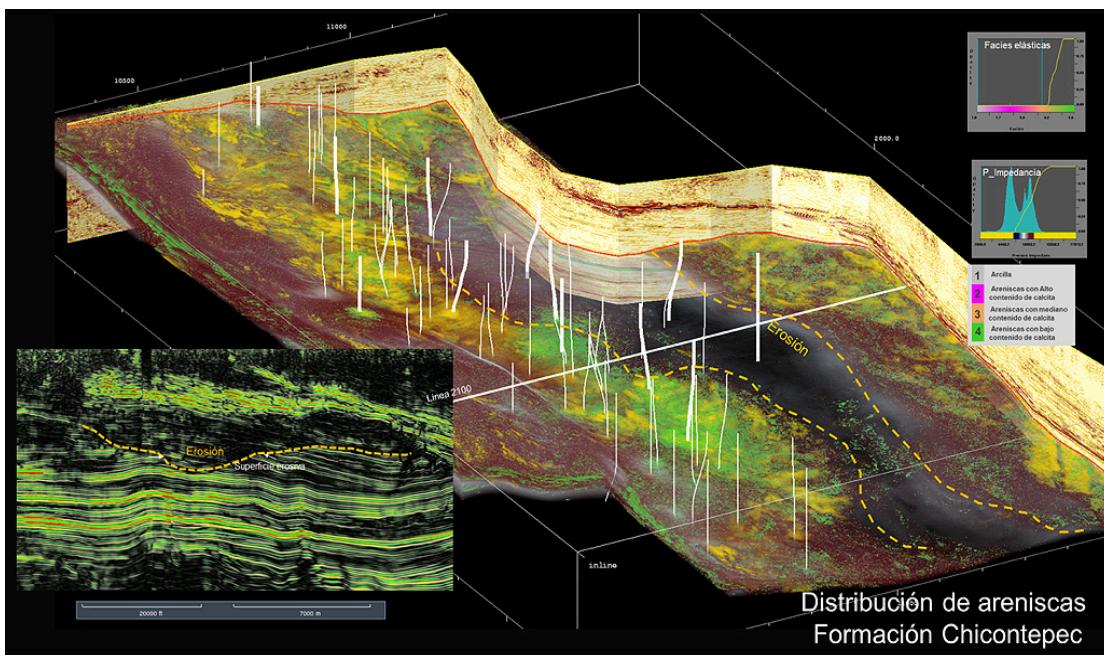
La Litofacies 4 se relacionó con los pozos cuyos intervalos disparados tenían buena producción y areniscas con menor contenido de calcita (mejor calidad de roca almacen).

La Litofacies 2 se relacionó con las areniscas con alto contenido de calcita o dicho de otra manera con menor calidad de roca almacen.



**Figura 6.** La imagen muestra el gráfico (a) impedancia p vs impedancia s pintada con el contenido de calcita, indicando, a mayor impedancia, mayor volumen de calcita, el gráfico (b) muestra la misma relación pintada con la facies elástica, donde se aprecia que la Litofacies 4 corresponde a menor contenido de calcita y mejor producción y las Litofacies 2 corresponden a las areniscas con mayor contenido de calcita.

La distribución de facies obtenidas muestra una predominación de las Litofacies 3 (moderado contenido de calcita) y una distribución de las Litofacies 4 (bajo contenido de calcita) en la porción central del área de estudio. Con la integración de la información de pozos, los resultados de la inversión simultánea a nivel de los rangos de impedancias y la distribución de facies se logró visualizar claramente las áreas con areniscas de menor contenido de calcita, las cuales han sido asociadas a los pozos con la mayor producción acumulada, para el intervalo correspondiente a la Formación Chicontepec.



**Figura 7. Distribución áreal de las areniscas con menor contenido de calcita para la formación Chicontepec.**

### Conclusiones

- Los resultados obtenidos permitieron mostrar una relación directamente proporcional entre los valores de impedancia y el contenido de calcita en la roca almacén.
- Mediante la integración sistemática de los resultados obtenidos, la inversión sísmica determinística y la información de pozos del proyecto, se lograron calibrar propiedades elásticas asociadas al contenido de calcita en las rocas almacenadoras.
- Se logró obtener una distribución de la Litofacies 4, presente en los pozos, que mostraron ser areniscas con menor contenido de calcita, representando así mejor roca almacén y de esta manera visualizar nuevas áreas de oportunidad.

- El uso de las técnicas de visualización e inversión sísmica determinística son una herramienta adicional para guiar el futuro plan de localizaciones.

- La distribución de facies elásticas por medio de redes neuronales, entrenadas con los productos de la inversión sísmica, permitirá jerarquizar las áreas con las facies asociadas a la mejor calidad de roca almacén en la formación Chicontepec, las cuales podrán ser usadas para proponer nuevas localizaciones (avanzadas).

### Agradecimientos

A Pemex por permitir la publicación de este trabajo.  
A los coautores, por su colaboración en el desarrollo del mismo.  
A la Coordinación del Programa Técnico CMP2019, por la



---

---

### **Rubén Charles**

Emerson

correo: Ruben.Charles@emerson.com

Ingeniero Geólogo egresado de la Universidad de Oriente (Venezuela), con más de 15 años de experiencia en la industria petrolera en Petrofísica en diferentes regiones de América Latina en yacimientos terrígenos y carbonáticos. Integrante de diversos equipos de estudios integrados de caracterización de yacimientos. Especialista en análisis e interpretación de registros especiales.

### **Cintya Galicia**

Emerson

correo: Cintya.Galicia@emerson.com

Cintya Galicia Andrés egresó en el año 2013 de la Carrera de Ingeniería Geofísica en la Escuela Superior de Ingeniería y Arquitectura del Instituto Politécnico Nacional. Recién egresada se integró a la compañía Paradigm en el área de soporte técnico hasta la fecha. Dentro de las actividades que desempeña está la interpretación sísmica, modelado de velocidades, modelado geocelular y evaluación petrofísica para grandes operadoras como Petróleos Mexicanos, Yacimientos Petrolíferos Fiscales Bolivianos y Repsol. Actualmente forma parte de la Comisión Editorial de la Delegación Paraíso-Comalcalco en la AMGP.













$$S_o = \frac{725*(V_p - 1)}{\sqrt{V_p}} \dots\dots\dots (1)$$

Donde:

$V_p$ , se encuentra en [km/s]

Por su parte, la ecuación para resolver el valor del coeficiente de fricción interna es la siguiente:

$$\mu = \tan \Phi \dots\dots\dots (2)$$

El esfuerzo de tensión que puede presentar la roca, bajo condiciones de no confinamiento, se expresa con valor negativo y es igual al valor del esfuerzo principal mínimo ( $\sigma_3$ ), en dichas condiciones. La expresión para determinar la magnitud de este parámetro es el siguiente:

$$T_o = \frac{UCS*(1-\sin \Phi)}{(1+\sin \Phi)} \dots\dots\dots (3)$$

### Redes Neuronales

Las redes neuronales (*RNs*), es una técnica de modelado flexible que se fundamenta en la eficiencia de los procesos nerviosos biológicos (Bishop, 1996; Haykin, 1999). Las *RNs* son capaces de descubrir relaciones lineales y no lineales entre datos numéricos con fines de análisis y predicción de comportamientos complejos.

Las principales ventajas de las *RNs* son:

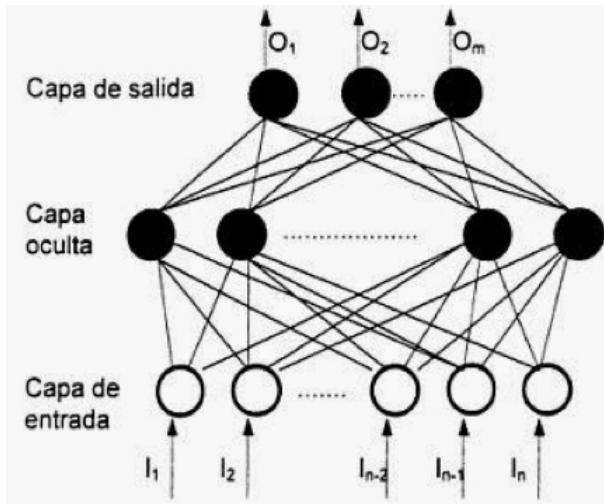
- i. Adaptación, ya que contrariamente a los métodos estadísticos tradicionales, las *RNs* no requieren hipótesis sobre la forma o distribución de los datos por analizar. Adquieren el conocimiento a través del entrenamiento o "experiencia" que "almacenan" como valores numéricos de los pesos de las conexiones neuronales.
- ii. Flexibilidad, las *RNs* tienen la capacidad para aprender y cambiar rápidamente en ambientes de alta dimensionalidad, no linealidad y definidos con un gran número de datos.
- iii. Tolerancia a datos imperfectos (ausencia de datos o problemas en la calidad), ya que la información es distribuida en las conexiones neuronales, lo que produce redundancia en el almacenamiento de la información y fortaleza ante imprecisiones o perturbaciones (Van Gerven, 2018).

En un sistema neuronal artificial se establece una estructura organizada en capas, cuya unidad básica es la neurona. Las capas constituyen a la red y las interconexiones entre las neuronas se llaman "pesos" (coeficientes numéricos en el funcional neuronal). La modificación iterativa de los pesos permite la adaptabilidad y representa la capacidad de predicción de las *RNs* (Kemp et al., 1997).

En general, las neuronas se suelen agrupar en unidades estructurales denominadas capas. Dentro de una misma capa las neuronas suelen ser del mismo tipo y el conjunto de capas constituye una red neuronal. Se distinguen tres tipos de capas (figura 2), (Kosko, 1992).

- Capa de entrada: compuesta por neuronas que reciben datos o señales procedentes del entorno.
- Capa de salida: aquella cuyas neuronas proporcionan la respuesta de la red neuronal.
- Capa oculta: aquella que no tiene una conexión directa con el entorno.





**Figura 2. Capas de una Red Neuronal Artificial (Pino et al, 2001).**

El aprendizaje de una RN consiste en determinar un conjunto de pesos sinápticos que permita a la red realizar una tarea. Para que la red resulte operativa es necesario entrenarla. Antes de iniciar el entrenamiento se debe definir la condición de ajuste a una tarea específica (cuando se dice que la *RN* ha aprendido). Entre los criterios más comunes se encuentran (Sigüenza et al, 1993):

- Se ha alcanzado una cota de error que se considere suficientemente pequeña.
- Se ha llegado a un número máximo de iteraciones.
- Se ha llegado a un punto de saturación en el que, por más que se entrene, ya no es posible reducir el error.

La fase de entrenamiento consiste en hacer que la red sea capaz de extraer, a partir de ejemplos, normas generales que le permitan en el futuro responder adecuadamente a patrones antes nunca vistos. Durante esta fase es imprescindible establecer una condición de paro óptima que minimice el error y evite un sobre-ajuste, es decir, que la red es incapaz de generalizar para casos nuevos. Existen dos métodos de aprendizaje: aprendizaje supervisado y aprendizaje no supervisado. La diferencia principal entre ambos estriba en la existencia, o no, de un operador o usuario (supervisor), que controle el aprendizaje de la red.

Existen muchas técnicas de aprendizaje supervisado, la que se empleó en esta investigación es el algoritmo Quick Propagation *QP* que opera rápidamente, debido a su sencillez, ya que el cálculo en cada conexión no es más que una multiplicación y una suma. De igual manera para ajustar los pesos de la conexión también realiza las mismas operaciones. Esto significa que en total el tiempo en el que se ejecuta el algoritmo depende de la velocidad en que el procesador pueda realizar dos multiplicaciones y dos sumas, lo que implica muy poco trabajo para cada conexión. Para profundizar más en el tema y obtener una explicación más detallada el lector puede consultar (Hassoun, 1995) y (Hertz et al., 1991).

Una vez obtenidos estos pesos, la red está lista para ser probada con patrones ajenos al entrenamiento. El objetivo de esta comprobación es observar el comportamiento de la red cuando las entradas son distintas a las que usaron en el entrenamiento. Al entrenar una red neuronal e intentar minimizar el error se corre el riesgo de sobre especialización (comportamiento óptimo con los ejemplos de entrenamiento, pero con casos distintos errores considerables). La minimización del error debe hacerse de manera equilibrada y muy cuidadosa, de tal forma que no origine una pérdida de generalización. Una vez que ésta resulte operativa, la arquitectura, neuronas, conexiones y pesos quedan fijos y la red está lista para funcionar. El conjunto de prueba debe ser i) significativo (debe contener ejemplos pertenecientes a todas las clases

establecidas) y ii) representativo (debe guardar la relación existente entre los ejemplos del conjunto de entrenamiento), (Bishop, 1996).

En su caso, García-Benítez (2009), analizó y utilizó redes neuronales, además de otros métodos de obtención con lo que llama cómputo suave (soft computing), para obtener la velocidad de corte mediante el cono de penetración para secuencias someras de roca. Con base en dicha investigación, se ha inspirado la extensión de la utilización de las *RNs* a la obtención de la  $V_s$  y elásticos, con aplicación en la industria petrolera.

#### Caso práctico en la obtención de la velocidad de corte y parámetros geomecánicos con redes neuronales

Los datos utilizados en este trabajo son principalmente curvas de registros geofísicos que han sido auditados para controlar la calidad. Son siete pozos para el proceso de entrenamiento de la red que se suman a nueve pozos con los que se probó y validó las salidas (parámetros) de la red neuronal.

Las variables de entrada, tanto para pozos de entrenamiento como para pozos de prueba, son inicialmente cinco y posteriormente se convierten en seis:

- A. Información de Profundidad (TVD)
- B. Registro de Rayos Gamma (GR)
- C. Registro de Tiempo de Tránsito (DT)
- D. Registro de Densidad Volumétrica (RHOB)
- E. Registro de Velocidad Compresional (VP)

Con el conjunto anterior y la información de velocidad de corte ( $V_s$ ), que se transforma de curva de salida a alimentación de entrada en cálculos subsecuentes, se obtiene información adicional para la obtención de varios parámetros geomecánicos, objetivos de este trabajo.

La información empleada para generar las redes neuronales de los registros anteriormente mencionados, entre pozos de entrenamiento y pozos de prueba, consta de la siguiente cantidad de datos:

<i>Tipo de Datos</i>	<i>Resolución Vertical [m]</i>	<i>Líneas de Datos (n)</i>
<i>Datos de entrenamiento: →</i>	<i>0.1524</i>	<i>52,132</i>
<i>Datos de prueba: →</i>	<i>2.0000</i>	<i>6,547</i>

Como puede notarse, la cantidad de datos de prueba es aproximadamente el 10% de los datos de entrenamiento, lo que se considera adecuado para controlar la evolución de los modelos y para asegurar que la validación es correcta. No obstante, debe mencionarse que los datos de entrenamiento corresponden a la información de siete pozos con una resolución vertical alta, mientras que los datos de prueba corresponden con la información de nueve pozos con una resolución vertical de dos metros.

En la figura tres se muestran las cuatro curvas de entrada de los siete pozos de entrenamiento condensado en un pseudopozo integrado, con la finalidad de obtener los parámetros geomecánicos con redes neuronales. Debe recordarse que la velocidad de corte ( $V_s$ ), inicialmente es un resultado o aproximación de una Red Neuronal (predicción), es decir, primero se estimaron las curvas de  $V_s$  para los nueve pozos de prueba y posteriormente se integraron como curvas de entrada.





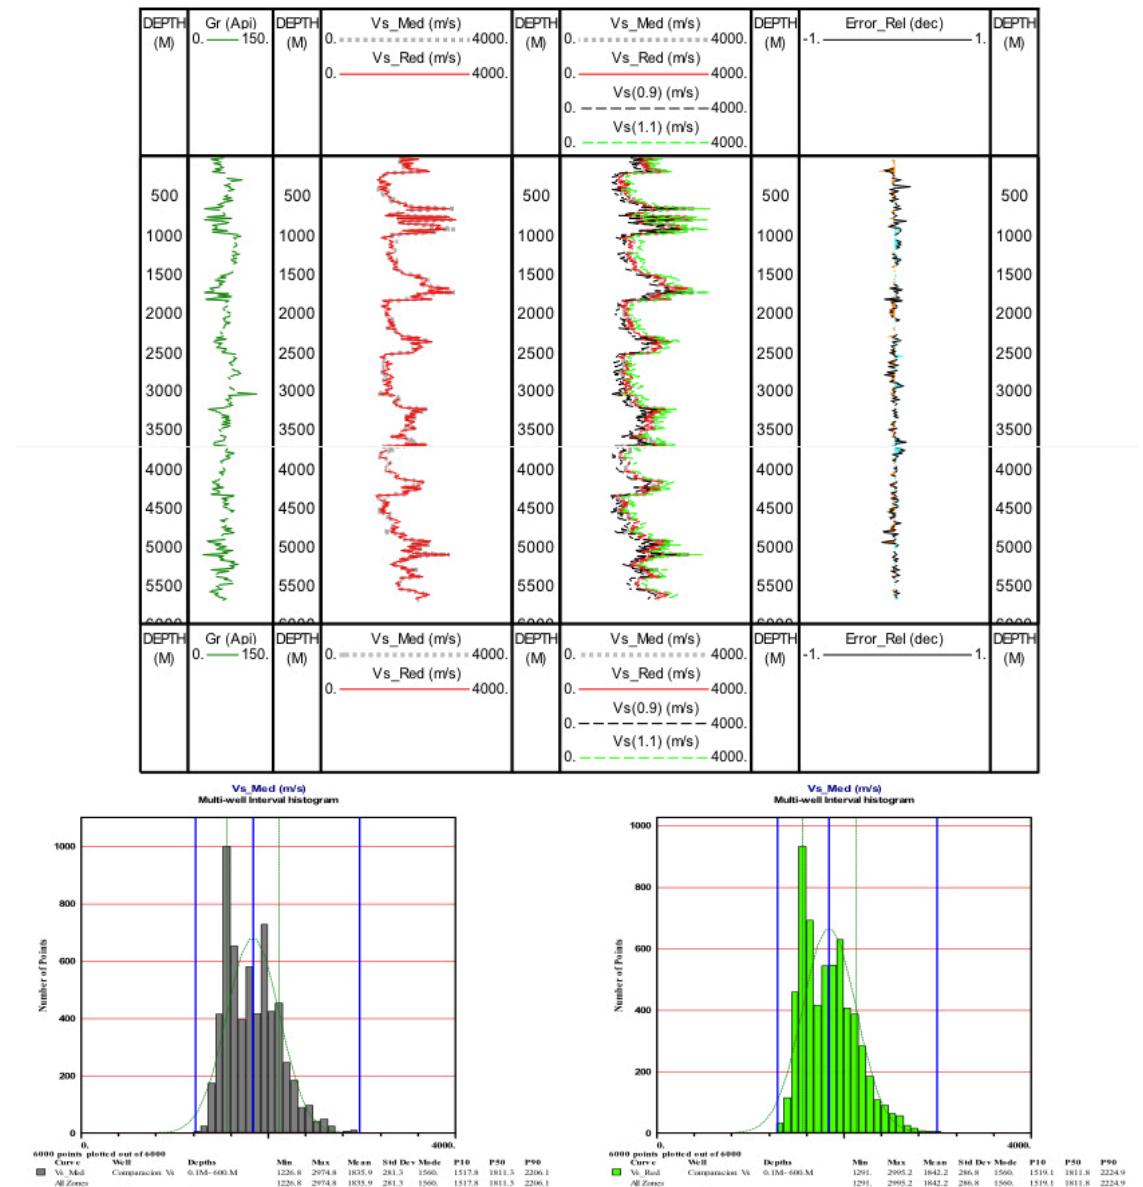
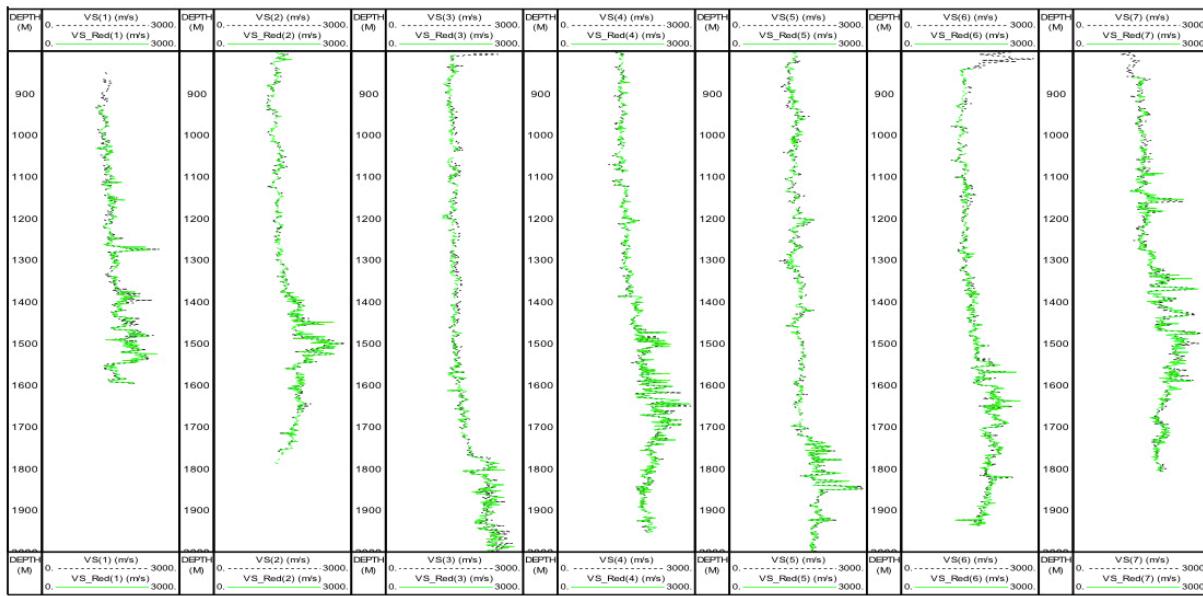
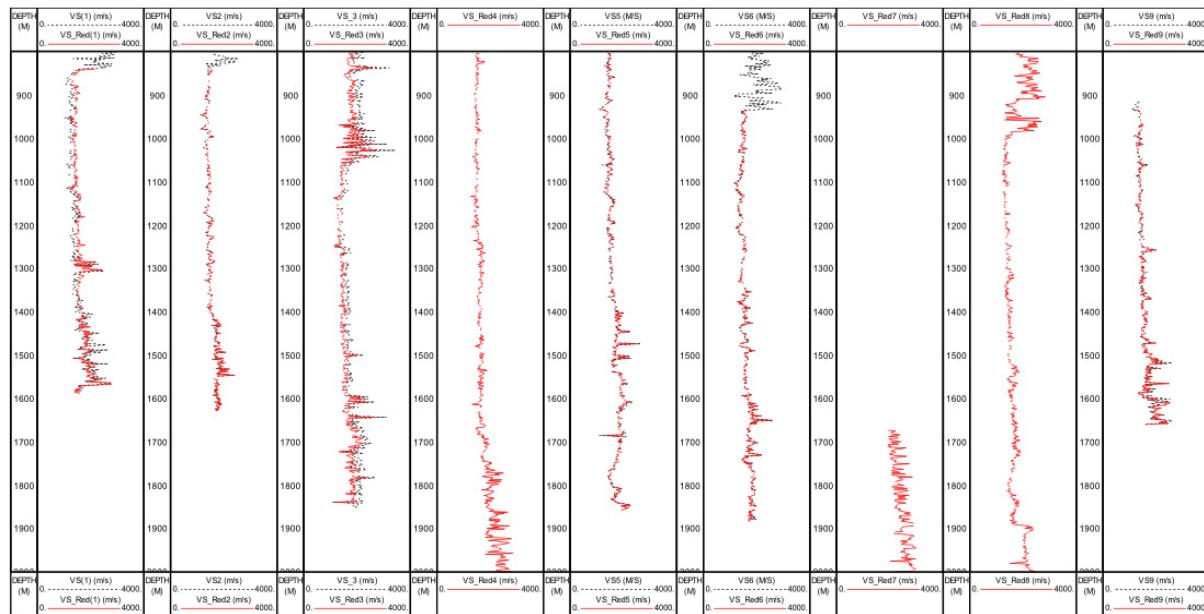


Figura 4.- Resultados obtenidos con redes neuronales para  $V_s$ .

Con los resultados obtenidos en los pozos de entrenamiento (figura cinco), se concluyó sobre la coherencia de operación de la red neuronal al analizar las velocidades de corte calculadas en los pozos de prueba (en los que no se cuenta con datos del registro DSI) (figura 6), lo que significó un camino alternativo para robustecer el conjunto de información disponible para análisis de geomecánica.

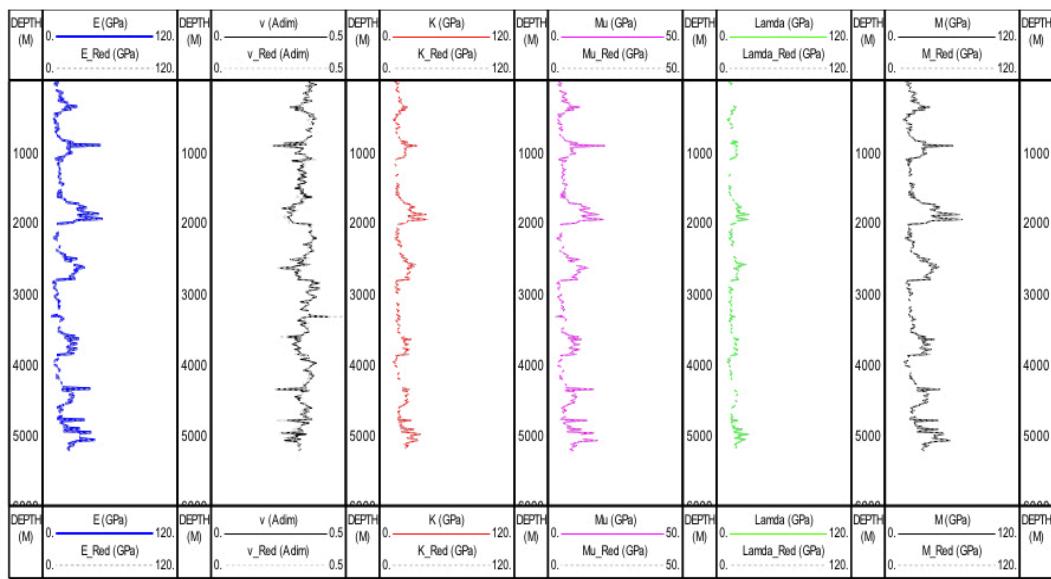


**Figura 5. Resultados obtenidos con redes neuronales para  $\text{VS}$ , para los pozos de entrenamiento.**



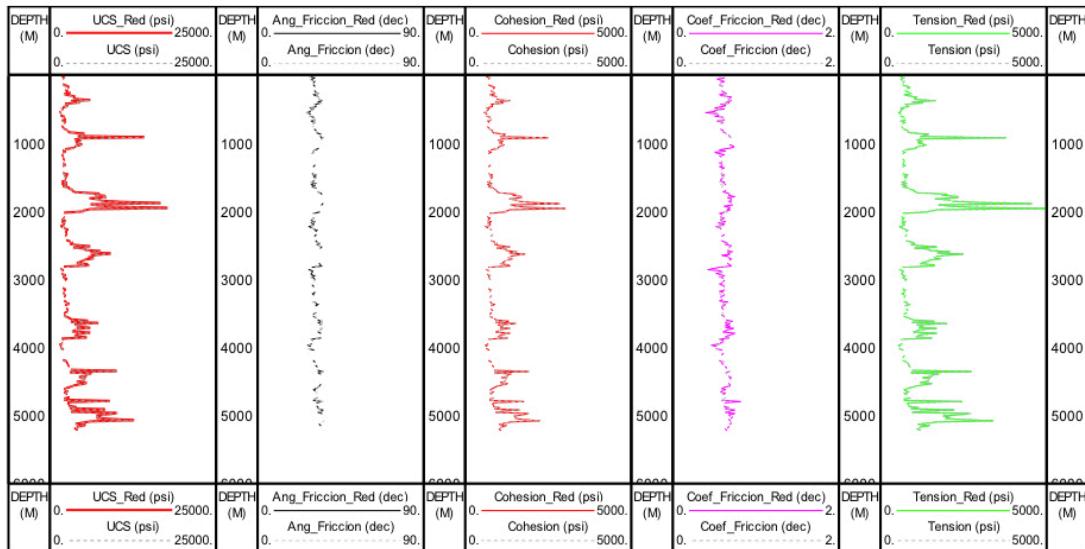
**Figura 6. Resultados obtenidos con redes neuronales para  $\text{VS}$ , para los pozos de prueba.**

Los resultados obtenidos para los parámetros elásticos de prueba, calculados con topologías neuronales, son satisfactorios, además de ser conseguidas en tiempos muy reducidos de cómputo (número de iteraciones < 1000) (figura 7).



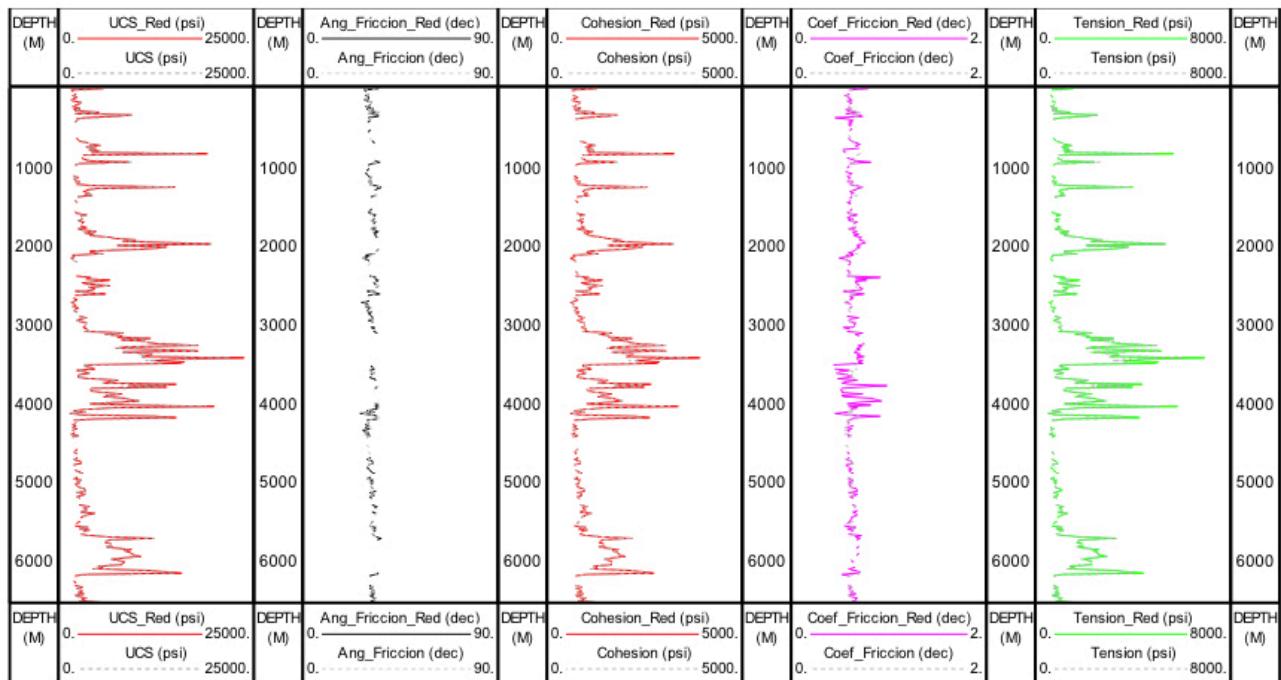
**Figura 7. Resultados obtenidos con redes neuronales para  $E, v, K, \mu, \lambda$  y  $M$ , para los pozos de prueba.**

Los resultados del modelado de parámetros de resistencia de la roca obtenidos de redes neuronales ( $UCS$ , Ángulo de Fricción Interna, Coeficiente de Fricción, Cohesión y Tensión), para los siete pozos de entrenamiento, muestran una buena correlación con los calculados. En la figura 8, se muestran estas aproximaciones.



**Figura 8. Resultados obtenidos con redes neuronales para  $UCS, \phi, S_o, \mu, T_o$ , para los pozos de entrenamiento.**

Por su parte, los resultados para los pozos de prueba muestran buena correlación con datos calculados (con otros métodos). Dada la independencia entre los resultados se considera que la red neuronal es eficiente (figura 9).



**Figura 9. Resultados obtenidos con redes neuronales para  $UCS$ ,  $\phi$ ,  $S_0$ ,  $\mu$ ,  $T_0$ , para los pozos de prueba.**

### Conclusiones y recomendaciones

La metodología empleada, a partir del entrenamiento de las redes neuronales para determinar la velocidad de corte y parámetros elásticos, fue satisfactoria y es extensible a la obtención de otros parámetros de interés petrolero.

Se obtuvieron curvas de velocidad de corte y parámetros elásticos, con un promedio de 96% de exactitud, contra datos medidos en campo, para los casos de entrenamiento, mientras que, para los datos de prueba, los resultados también presentan una correlación bastante aceptable con datos calculados.

La exactitud obtenida con redes neuronales, no había sido obtenida con ninguna correlación disponible en la literatura para ninguno de los parámetros. Adicionalmente, se vislumbra como ventaja práctica en el uso de esta técnica que, mediante el entrenamiento adecuado de una cantidad pequeña de datos, puede

extrapolarse a áreas de grandes dimensiones con características similares.

Fueron puestas en práctica las características descritas en la literatura para definir a las redes neuronales (adaptación, flexibilidad, la tolerancia a datos imperfectos), al someterlas a diferentes condiciones de cálculo de diferentes paquetes de variables, como se ha mostrado en este trabajo.

Con los resultados obtenidos, es posible integrar un modelo de geomecánica 1D para cada pozo o pseudopozo en diferentes áreas de estudio con relativamente poca información.

A partir del punto anterior, se pueden construir modelos tridimensionales (3D), que permitan definir en cualquier punto del espacio valores de elasticidad, resistencia, esfuerzos, etc.; esto de gran utilidad para contribuir a la identificación de zonas con las mejores características para la explotación de hidrocarburos.



# Flujo Tecnológico Aplicado a la Identificación de Facies Sísmicas Calibradas con Información de Pozos en Áreas de Exploración Aguas Profundas

Autor: Edgar Eloy Medina Martínez (Emerson Paradigm)

Coautor: Jessica Salgado Mendoza (Emerson Paradigm)

CMP2019\_216

Artículo presentado  
en el CMP / 2019  
(versión en español)

## ● Resumen

PEMEX, la principal empresa productiva del Estado mexicano, tiene dos grandes áreas en el norte del Golfo de México costa afuera, conocidos como el "Cinturón Plegado Perdido" y el "Área Subsalina", figura 1, proyectos catalogados de Agua Ultra Profundas y considerados entre los más importantes de la estrategia nacional de exploración. El presente trabajo consiste en proponer una solución para obtener un resultado cualitativo y cuantitativo del cálculo de reservas posibles, dependiendo de tres factores

clave: el primero es honrar las litofacies de pozo dentro del modelo propuesto, preservando la máxima resolución vertical, el segundo generar apropiadamente un modelo del subsuelo con la información sísmica y por último, estimar correctamente el volumen neto de aceite, variables que dependen de importantes factores, siendo la resolución sísmica uno de los más importantes, dado el limitado contenido de frecuencia en los niveles objetivo, por lo que es crucial la correcta integración de dichos factores para garantizar que el volumen de aceite calculado esté dentro de un contexto geológico en los pronósticos de reservas.

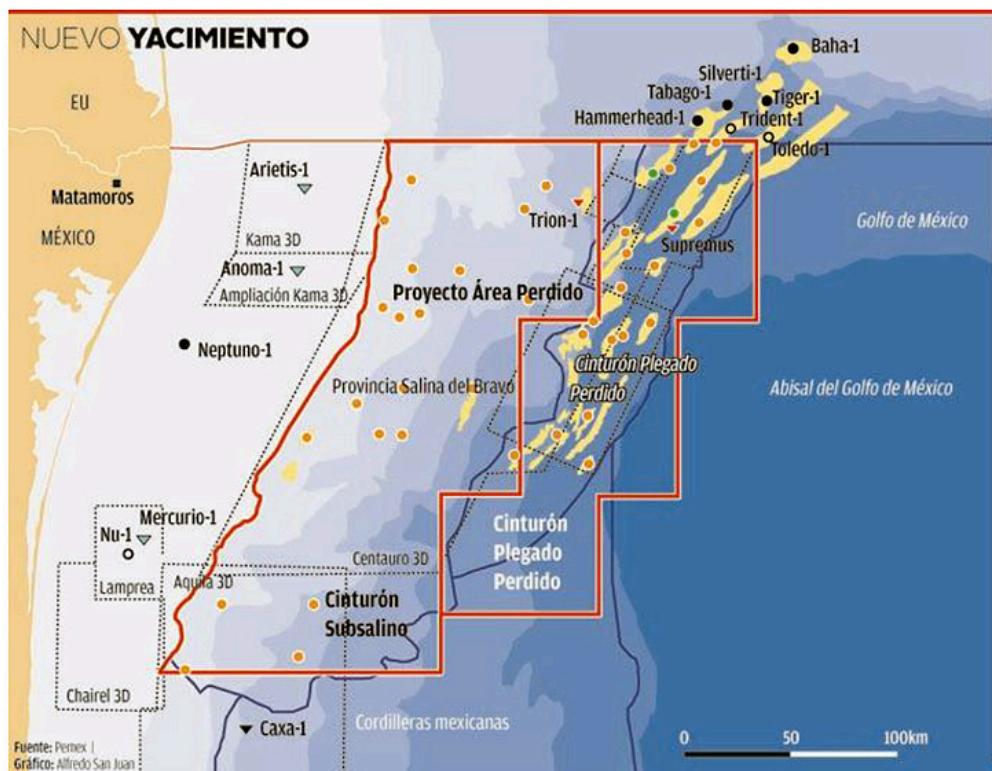


Figura 1. Área de estudio correspondiente al Cinturón Subsalino y Área Plegado Perdido. Fuente <http://energia.org.mx/wp-content/uploads/2012/09/PozoTrionPrimerDes-cubrimiento3.pdf>.

La metodología propuesta consiste en integrar los resultados de una tecnología de redes neuronales ('Neural Network Technology'), desarrollada por la empresa TOTAL. (1998, all rights reserved), junto con el algoritmo Tau (Journel, 2002), el cual se aplica a la traza sísmica y a la información litológica de pozo de manera conjunta. El modelo de sismofacies obtenido se integra a un modelo geocelular tridimensional, con la finalidad de coadyuvar en el incremento del espectro de frecuencia para mejorar la resolución vertical y lateral usando técnicas alternas de probabilidad numérica.

Durante el entrenamiento de estas probabilidades, es posible tener un pronóstico de litofacies de pozo sustentado con un modelo geológico "más probable", ya que el algoritmo utiliza una exploración inteligente de las funciones de densidad de probabilidad PDF ('Probability Density Functions') de muestras, maximizando las simulaciones geoestadísticas supervisadas para encontrar una solución óptima en los tiempos de ejecución y explotando de manera eficiente cantidades de resultados para una correcta interpretación global del subsuelo. Para ilustrar la técnica, presentamos ejemplos obtenidos con datos abiertos en internet, así como de diversas fuentes públicas de la Universidad Autónoma de México y del Instituto Politécnico Nacional, boletines oficiales de la Comisión Nacional de Hidrocarburos, incluyendo autorizaciones especiales para mostrar los resultados de manera "ilustrativa" por parte de Pemex Exploración y Producción (PEP), así como de la revisión técnica de la Asociación Mexicana de Geofísicos de Exploración AMGE, Delegación Poza Rica (Asamblea Local, 2017).

Este flujo de trabajo permitió también garantizar un análisis interpretativo de forma cuantitativa para poder comparar los modelos geológicos obtenidos con el modelo conceptual y visualizar las iteraciones geométricas que se establecen entre estos. Al final, el resultado, clasificado como Bayesiano, debe tener una relación directa con cubos tridimensionales de probabilidad litológica, de tal manera que la predicción de litofacies pueda estar asociada directamente con la geología y con los registros geofísicos calculados en los pozos delimitadores. La metodología y resultados obtenidos se aplicaron en Aguas Ultra Profundas del Golfo de México.

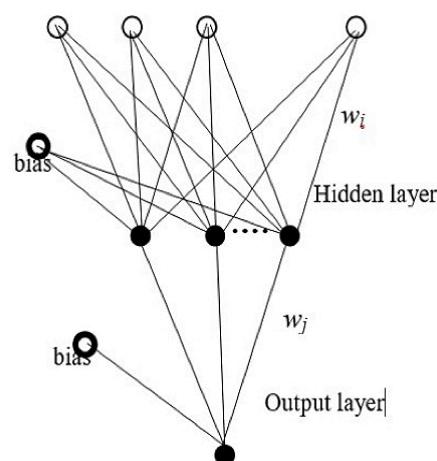
## Método y teoría

La búsqueda de puentes entre los estudios de prospectos para la caracterización de un yacimiento es un objetivo que podemos resolver mediante una combinación de técnicas de redes neuronales

y de la estimación de probabilidades por el algoritmo de Tau en un modelo geocelular, en el cual el objetivo es predecir un modelo de litofacies empleando atributos elásticos derivados de la inversión sísmica y/o traza compleja, para el caso propuesto, con métodos estadísticos (Caers, Avseth y Mukerji, 2010). Para conseguir esto, en la primera fase se busca obtener los atributos sísmicos que tengan una máxima concordancia con el modelo conceptual sedimentario para posteriormente calibrarlo con datos petrofísicos de pozos evaluados.

El concepto de tiempo, para la teoría neuronal, se conoce como el número de ciclos de una red numérica. La neurona trata n valores de entrada como si fueran una sola unidad; esto recibe el nombre de entrada global, por lo que el problema se puede combinar con entradas simples de esas muestras. Un resumen esquemático se muestra en la figura 2, donde indica una serie de entradas lógicas sobre un ciclo de entrenamiento de procesos complejos para salidas discretas, esto se logra a través de una función de inicio, la cual se calcula a partir del vector inicial.

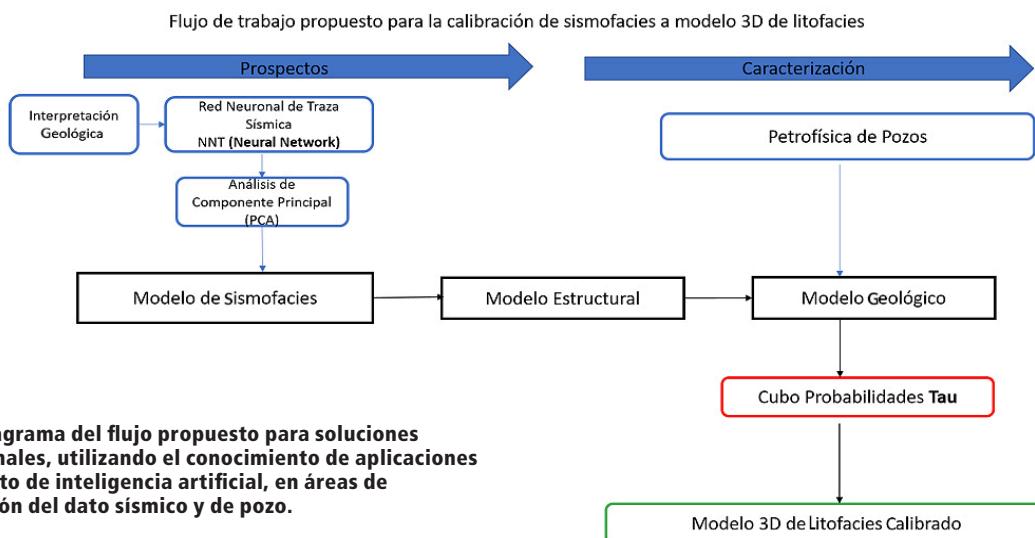
Los valores de entrada se multiplican por pesos o muestras previamente ingresados a la neurona, que generalmente son variables incógnitas en el proceso de entrenamiento-aprendizaje. La salida es un operador perceptrón multicapa de convolución (Fausett, 1994, Calderón et al, 2000). Estos operadores de salida estarán representados por geometrías numéricas.



**Figura 2. Neurona con n entradas y una salida operador perceptrón generada a partir de funciones matrices de entrenamiento.**

## Aplicación en el análisis geológico sísmico

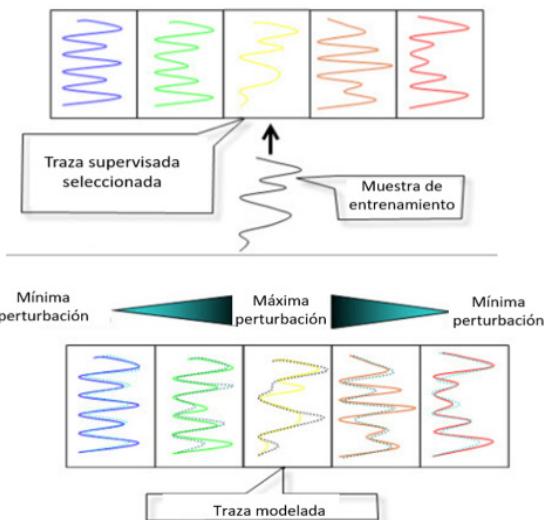
El flujo de trabajo propuesto se muestra en el diagrama de la figura 3, mostrando la conexión entre un modelo de sismofacies usando la teoría neuronal y su correcta incorporación a un modelo de litofacies mediante el algoritmo de Tau. Esto, no solamente en el contexto tradicional de mapas 2D sino introduciendo un concepto de análisis 3D.



El algoritmo NNT pertenece a la clasificación de aprendizaje delta o regla del mínimo error cuadrado (LMS- Least Mean Squared Error), que utiliza la desviación estándar numérica de la muestra a la salida objetivo previamente definida, tomando en consideración a todas las neuronas predecesoras. Esto permite cuantificar el error global cometido en cualquier momento durante el proceso de entrenamiento de la red, lo cual es importante, ya que entre más información se tenga sobre el error cometido, más rápido ésta puede "aprender" del error calculado ( $\delta$ ), repartido entre las conexiones de las neuronas predecesoras (Kriesel, 2005), donde básicamente se ejecuta un proceso de inteligencia artificial que busca patrones recurrentes de trazas y crea un conjunto de muestras que son representativas de todo el conjunto de datos, integrando en esta circunstancia el concepto de clases.

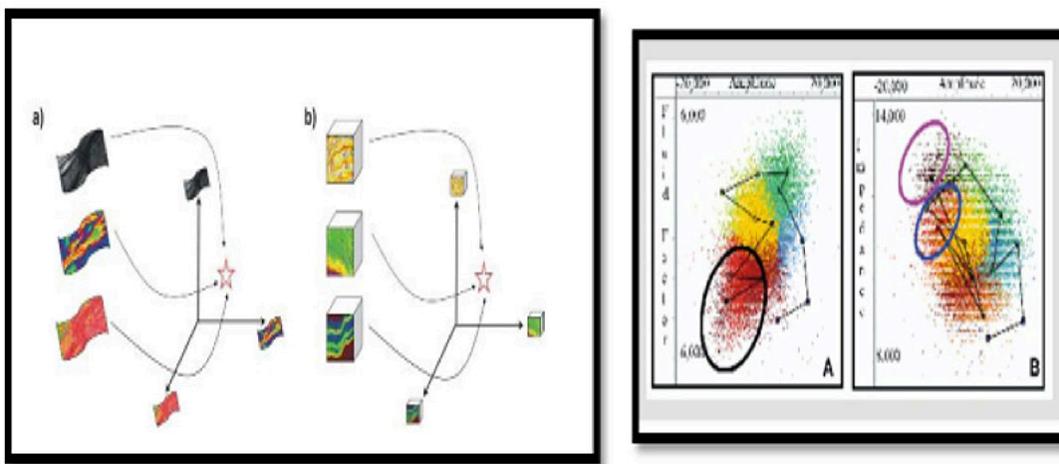
El número de clases estimado no es crítico, a diferencia de otros métodos de agrupación, ya que los rastros del modelo están fuertemente correlacionados con sus muestras vecinas inmediatas. El proceso actúa cíclicamente siendo éstas supervisadas a un patrón espacial ( $x, y, z$ ) del conjunto de datos. Una vez que se crea la traza modelo, comúnmente referida a la posición de los pozos de

interés, se integra a un tipo de clase/facies definidas con un valor característico como se observa en la figura 4.



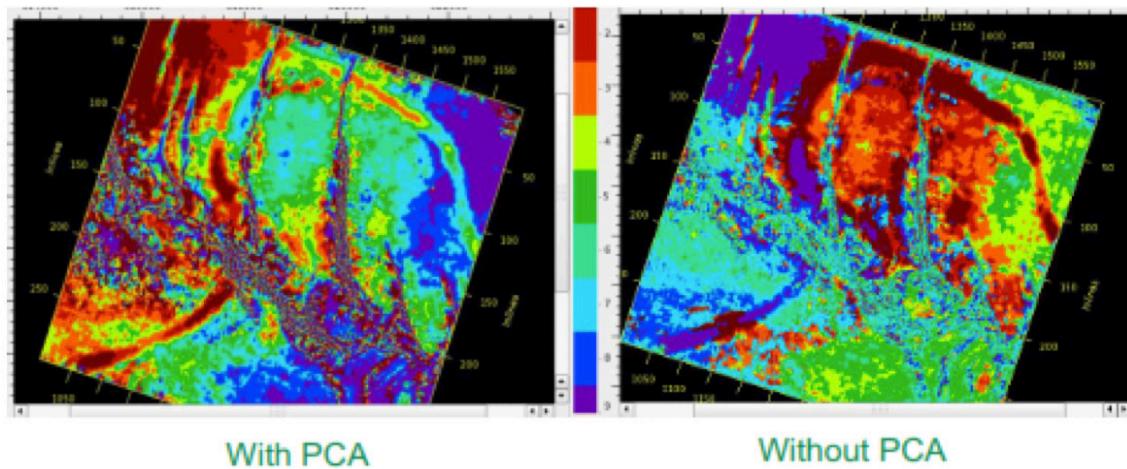
**Figura 4. Generación del modelo de trazas, a partir de una muestra de entrenamiento, para la obtención de muestras/facies análogas definidas.**

Se introduce en el proceso el término PCA, figura 5, para referirse al análisis de componentes principales aplicadas directamente en los datos de atributos sísmicos, interactuando en forma de bloques de clases/facies en la coordenada de interés supervisada, correspondiente a la trayectoria de pozo productor y así obtener una serie de clases filtradas, para clasificarlas en un conjunto de similitudes integradas que permitan correlacionar patrones de traza sísmica de interés.



**Figura 5. Redes neuronales en la generación de tipos de clases sísmicas, como resultado de las combinaciones de multi atributos en el análisis PCA y sus clasificaciones de corte, para integrar un conjunto de bloques que serán denominados sismofacies.**

El proceso es muy útil para reducir el número de iteraciones y evitar la redundancia y el ruido en la traza sísmica, no sobreestimando la traza modelo, enfocándose en agrupar y resaltar la clase/facie dominante que pueda obtenerse basada en las características estratigráficas a gran escala (geometría de depósito regional). Dicho proceso, se emplea en mapas interpretados en los intervalos de los yacimientos de interés, como se observa en el ejemplo de la figura 6.



**Figura 6. En los mapas, se ilustra los contrastes de un análisis de sismofacies supervisado. Por ejemplo, en el mapa sin PCA (derecha) se obtiene una geometría de canal, sin embargo, no se observan cambios delimitantes en las clases resultantes, caso contrario en el mapa con PCA (izquierda), donde las clases son más continuas, pero también más definidas, ya que mejora los patrones internos indicándonos cambios de facies mejor perfilados en la interpretación geológica.**

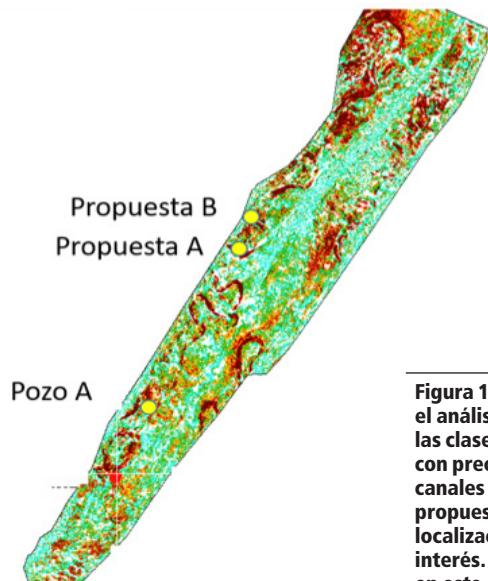






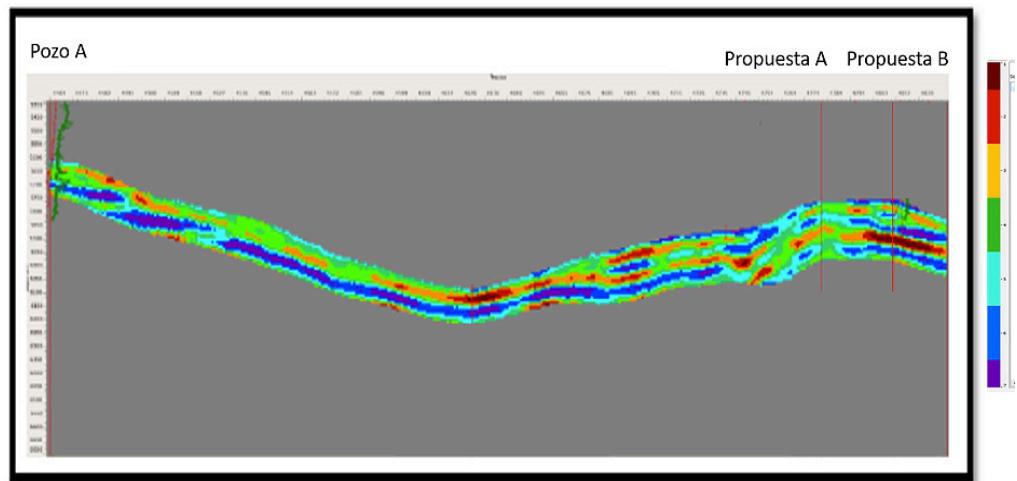


En el último paso de este proceso, se ejecuta toda la extensión del área del yacimiento, lo cual es crucial para verificar la continuidad de las clases 5 y 7, ya que el enfoque neuronal combina la capacidad de realizar un análisis multidimensional de los datos sísmicos con el análisis de interpretación de las facies obtenidas. Fundamentalmente, este paso muestra la posibilidad de dar un resultado eficiente que reduzca la incertidumbre en la prognosis geológica de los yacimientos delimitadores. En la figura 14, se muestra una predicción de facies más probable como un resultado de este análisis, la cual provee una visión y perspectiva clara para calificar una oportunidad de desarrollo con una proyección de éxito, al recalcar las posibilidades de correlación con el resultado inferido.



**Figura 14.** Estructura total analizada con el análisis de sismofacies expandiendo las clases supervisadas y delimitando con precisión la geometría de los canales de interés, permitiendo tomar propuestas de caracterización en localizaciones con las sismofacies de interés. La clase 5 es la mejor candidata en este escenario.

Complementamos el análisis con un perfil del modelo de sismofacies como se muestra en la sección de la figura 15. Utilizamos la clase 5, como la mejor opción para ejecutar esta traza modelo a lo largo de toda el área de interés. A partir de esta operación, se refinan dos posiciones A y B como opciones de pozos delimitadores.



**Figura 15.** Perfil de sismofacies que nos da 2 escenarios en las propuestas del pozo a perforar usando la correlación de la clase 5 supervisada. Este perfil de sismofacies se usa como un primer diagnóstico en los pronósticos de las áreas delimitadoras del yacimiento.

### Estimación de modelos de probabilidad TAU tridimensional calibrada con petrofísica de pozos

La última etapa del flujo se aplica usando los resultados del modelo de sismofacies obtenido y ubicadas las posiciones A y B de la clase 5, previamente definida. Dichas posiciones se utilizarán en el cubo de isofrecuencia de 30 Hz, para calibrar la respuesta sísmica con la información petrofísica de pozos. Tanto la propiedad sísmica como los registros de pozos se incorporarán a un modelo geocelular.

El modelo de celdas funciona como un puente entre las áreas de prospectos con la de caracterización y delimitación de yacimientos. Una de las ventajas, es dar la facultad de justificar modelos con mayor resolución para definir un yacimiento en sus dimensiones verticales y laterales, en toda su extensión, para una correcta caracterización del yacimiento (Jayr et al., 2008; Souche et al., 2013; Souche et al., 2014; Mallet, 2014; Labrunye and Carn, 2015).

El modelo de celdas, en la cobertura de estudio, se construyó manteniendo el bin sísmico de procesamiento, mientras que para los parámetros del muestreo vertical se utilizó la media de los registros geofísicos de pozo. El modelo se construyó lateralmente con un promedio de 25 X 12 metros y 0.25 metros verticales para poder garantizar la máxima resolución posible, situación que al nivel del desempeño de las estaciones de trabajo demanda mucho nivel de recurso de hardware. Por lo tanto, es de puntualizar que esta etapa es crítica por los tiempos de respuesta. Una de las estrategias, fue sectorizar las áreas de interés para parametrizar correctamente la construcción estructural, sobre todo en lo que se refiere al escalamiento de los valores de registros a las celdas. El resultado de lo que se conoce como modelo sólido es referido a la malla geológica final como se observa en la figura 16, siendo la base para la distribución de cualquier propiedad física de interés.

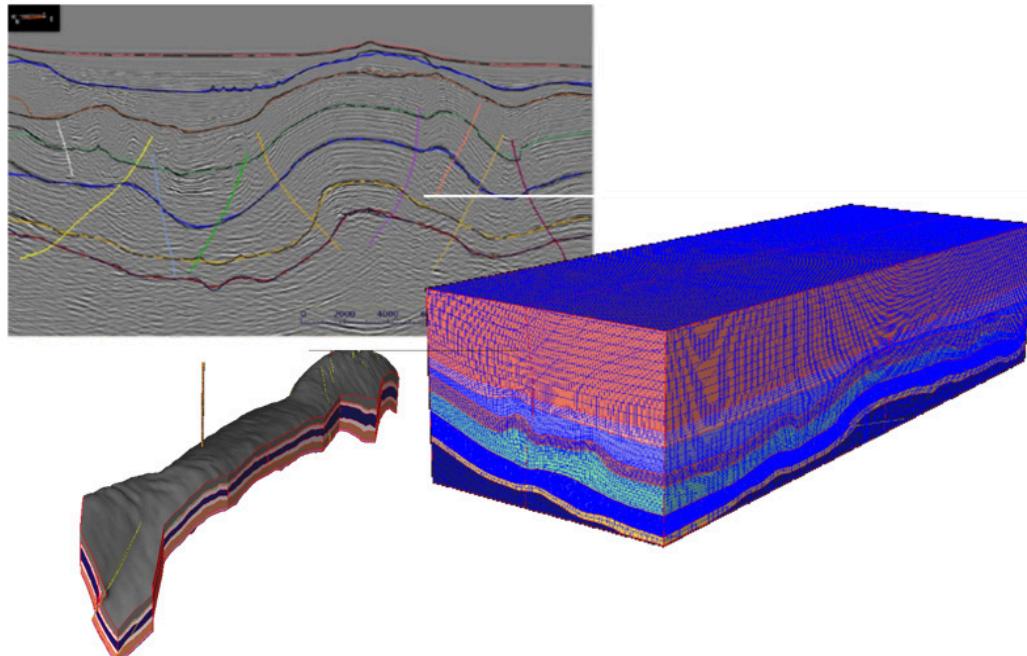


Figura 16. Se muestra el arreglo geoespacial y la reconstrucción estructural del área de estudio, así como la preservación de la ortogonalidad de las celdas y la complejidad estructural de las interpretaciones. El resultado, es un modelo geológico con alta resolución, para la recuperación de la información litológica dentro del modelo de facies. En el proceso final, se garantiza la correcta propagación de litofacies en el contexto 3D para propuestas de caracterización.

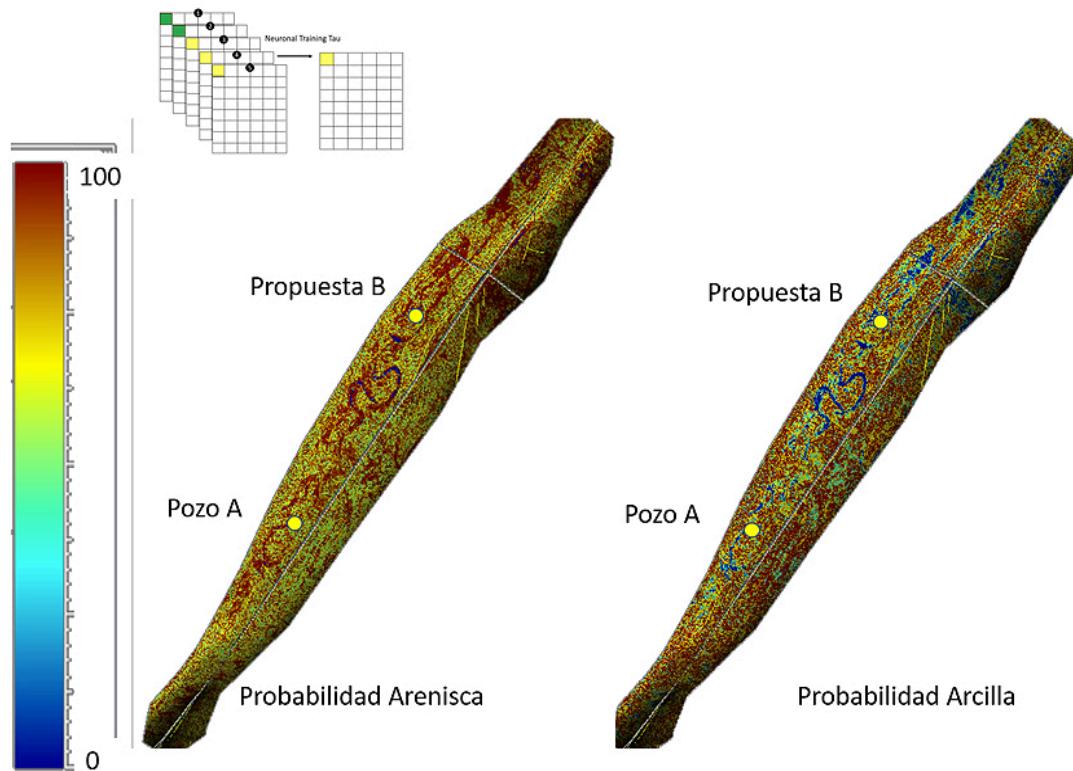


A pesar de la evolución del proceso en esta fase, aún está como incógnita el tipo de litofacies que se estará pronosticando. Sin embargo, lo que sí podemos interpretar y reconocer en este nivel del flujo es el porcentaje de la muestra de manera numérica. Una vez que el algoritmo interpola los resultados de las barras de calibración en toda la malla geológica, el resultado de las iteraciones son cubos normalizados por tipo de roca (Arenisca, Arcilla), como se observa en la figura 18, resaltando las características del modelo conceptual previamente identificado en la figura 13, de tal manera que este resultado logra satisfacer la hipótesis planteada en la interpretación, solucionando un problema concurrente en la cadena de trabajo de Exploración y Producción.

Una vez que los cubos de probabilidad por tipo de roca están generados, se determina el método de distribución de

las propiedades litológicas del dato de pozo dentro de estas probabilidades validadas. El método normal truncado es el algoritmo óptimo bajo estas condiciones, ya que la solución del problema inverso es la distribución de probabilidad a priori (Voge, 2002), además de facilitar el uso de variogramas por zonas definidas para lograr obtener modelos transicionales de ambientes de depósito, permitiendo honrar todo el dato acondicionado.

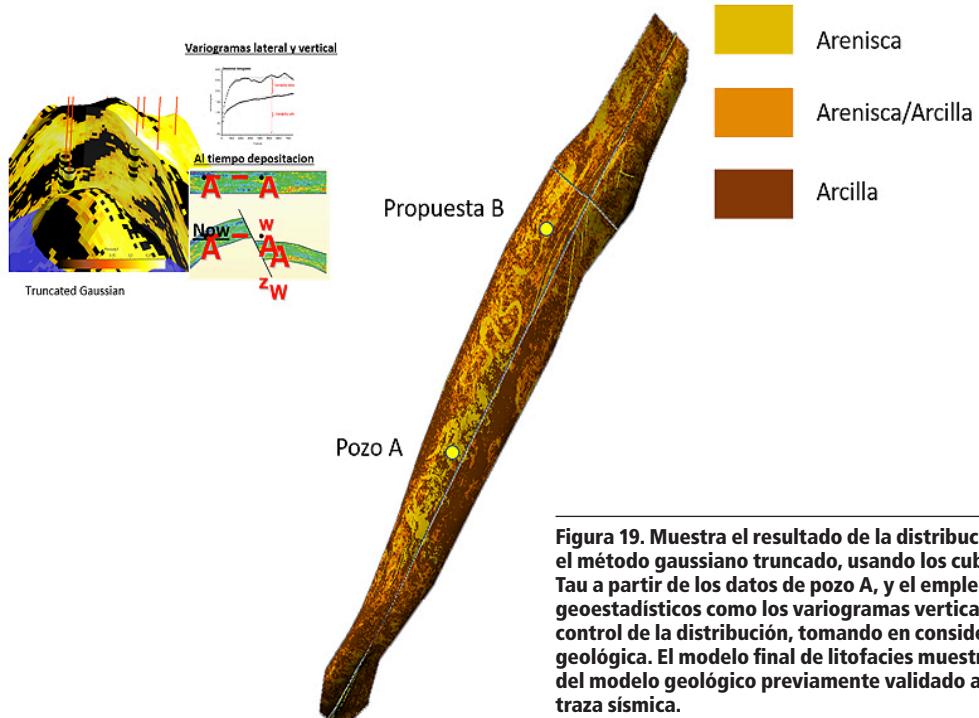
El reto de los resultados es revisar y confirmar si la correlación de las informaciones conocidas concuerda con la predicción del modelo propuesto, y la manera óptima es comparando el modelo de litofacies con los datos duros del pozo A conocido, para la justificación de la caracterización y estar en condiciones de emitir recomendaciones sobre el agregar este tipo de análisis en los flujos convencionales de interpretación para la delimitación de yacimientos de exploración.



**Figura 18. Cubos de probabilidad como resultado de las barras de calibración Tau, mostrando la correlación de la traza sísmica con el valor litológico del pozo muestra a muestra, para obtener los "pesos" de probabilidad en cada unidad de roca. Los mapas indican la evolución de la metodología. En el rango, se muestra que hacia los colores cálidos (rojo), se delinean la geometría de canal asociado a las areniscas, mientras que hacia los colores fríos (azul), valores asociados a una arcilla.**

Es importante el resultado visual que se observa porque es un control para la continuidad del proceso. Normalmente, las identificaciones de estos patrones geométricos se obtienen por procesos convencionales de interpretación en mapas 2D, a través de la visualización de multiatributos en ventanas de interés. En este caso, el valor del flujo propuesto remarca que el resultado final está en términos tridimensionales que logren asociar correctamente la estimación del volumen de yacimiento, siempre coherente con la geología interpretada, para la incorporación de una reserva estimada que sea precisa y pueda ser económicamente atractiva para su desarrollo.

Los cubos interpolados concuerdan con la regresión lineal obtenida con la clase 5, a partir de los análisis de componente principal PCA, muy aceptable en términos litológicos del pozo A y su distribución geométrica (cubos de probabilidad). El resultado es el modelo de litofacies mostrado en la figura 19, el cual se considera el más probable después de cientos de iteraciones en los algoritmos truncados aplicados, hasta su estabilización en las simulaciones ejecutadas. La localización referida como propuesta B, se mantiene en la posición inicial establecida con el modelo de Sismofacies NNT clase 5, solo que ahora en los términos de clasificación de litofacies obtenida por la Inversión Tau.



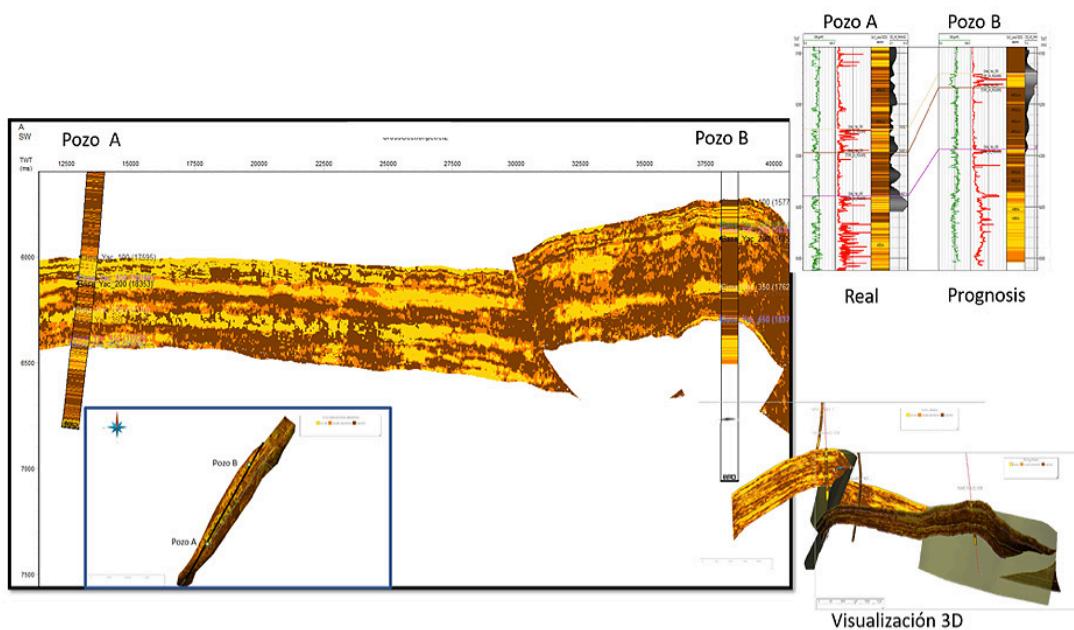
**Figura 19.** Muestra el resultado de la distribución de litofacies por el método gaussiano truncado, usando los cubos de probabilidad Tau a partir de los datos de pozo A, y el empleo de accesarios geoestadísticos como los variogramas verticales y laterales para el control de la distribución, tomando en consideración la complejidad geológica. El modelo final de litofacies muestra evidencia geométrica del modelo geológico previamente validado a partir del análisis de la traza sísmica.

La correlación del modelo de litofacies entre el pozo A conocido, y la propuesta B, es mostrada en la figura 20. Este modelo es verificado posteriormente con los registros evaluados GR y RT de la trayectoria del pozo B "incógnita", durante la etapa de perforación y evaluación petrofísica, con el objetivo de revisar y cuantificar la incertidumbre de los resultados. Como se observa, el modelo muestra los cambios de facies a lo largo de la estructura hacia el pozo B "incógnita". Este resultado pone en evidencia la precisión entre los registros geofísicos "reales" del pozo B que, una vez terminada la fase de perforación, terminación y evaluación petrofísica, sus valores de corte para delimitación de tipo de roca concordaron con las litofacies predictivas, mostrando coherencia con la interpretación geofísica y petrofísica.

Este resultado está basado en los parámetros numéricos establecidos en las simulaciones, y la aplicación de correcciones en los variogramas, así como en ejecutar diversos escenarios de los histogramas, condiciones esenciales para determinar una factibilidad de los

procesos y así proponer y cuantificar no solamente un modelo geológico valido, sino una reserva de hidrocarburo confiable.

En detalle, se puede observar en la correlación de la figura 20, el cambio de facies predictivo en la entrada de la cima del yacimiento, que para el pozo A conocido es una arenisca menos arcillosa que la entrada del pozo B propuesto, que es un intervalo totalmente arcilloso. Esto es importante porque permitió realizar un ajuste en la determinación del objetivo principal productor previo a la perforación, lo cual fue revelador al observar la convergencia del resultado del modelo con los registros petrofísicos reales del pozo B, determinando en esta fase del análisis la obtención exitosa de una calibración geométrica del yacimiento con la resolución litológica de la trayectoria de los pozos en estudio.



**Figura 20. Sección del modelo de litofacies entre el pozo A conocido y el pozo B predictivo, indicando el cambio de litofacies, así como también la confirmación del modelo verificado con los valores de corte de los registros del pozo B, incorporados después del modelo propuesto.**

Finalmente, se realiza un cálculo volumétrico de reservas con parámetros previamente determinados por las pruebas de producción y análisis de laboratorio. Estos valores, incluyendo los relacionados al factor de volumen de formación Bo, factor de recuperación del gas/aceite, porosidad y saturación de agua, se mantienen en estado de confidencialidad. Los resultados de este estudio son mostrados en la tabla 1, en donde se indica una comparación del volumen obtenido del modelo de litofacies dentro de los yacimientos para el Eocene Inferior, formación Wilcox. Como se puede observar, los resultados de la estimación de la reserva probable son muy cercanos al estimado real, lo cual nos permitió validar e incorporar el estudio como un apoyo adicional para la fase final en el modelado petrofísico, aportando una solución determinística para la estimación de reservas oficiales.

Escenario Base (mmbpce)	LC + 50 m (mmbpce)	LC + 100 M (mmbpce)	Escenarios
111	131	156	Reservas Posibles Totales
120	135	213	Reserva Estimada con el Modelo Litofacies

**Tabla 1. Tabla comparativa del volumen de reservas predictivo, a partir del modelo de litofacies, y las reservas 3P emitidas por CNH en páginas oficiales, para el yacimiento de estudio.**

## Conclusiones

La combinación de los algoritmos neuronales y Tau, en aplicaciones tecnológicas para estudios del subsuelo, permite una optimización global para predecir modelos litológicos mediante un entrenamiento aleatorio no lineal, apoyado con la combinación de multi atributos para la supervisión de la traza sísmica de enfoque, permitiendo la búsqueda de soluciones en forma simultánea, haciéndola más eficiente y generando probabilidades más estacionarias en su solución.

En el caso presentado, la metodología obtuvo soluciones muy apropiadas y coherentes, con alta precisión, al confirmarse y validarse con los datos duros de la petrofísica del pozo propuesto B, a partir de las facies predictivas. Estos volúmenes litológicos tridimensionales proveen una variable adicional para la interpretación sísmica cuantitativa, agregando valor a los productos de inversión sísmica y física de rocas.

Es importante tomar en cuenta que, para garantizar buenos resultados, el coeficiente de correlación debe ser cercano a 1 entre las

Proyectos en la generación de modelos de sismofacies (NNT) hasta los modelos 3D de Litofacies calibrados (Tau)

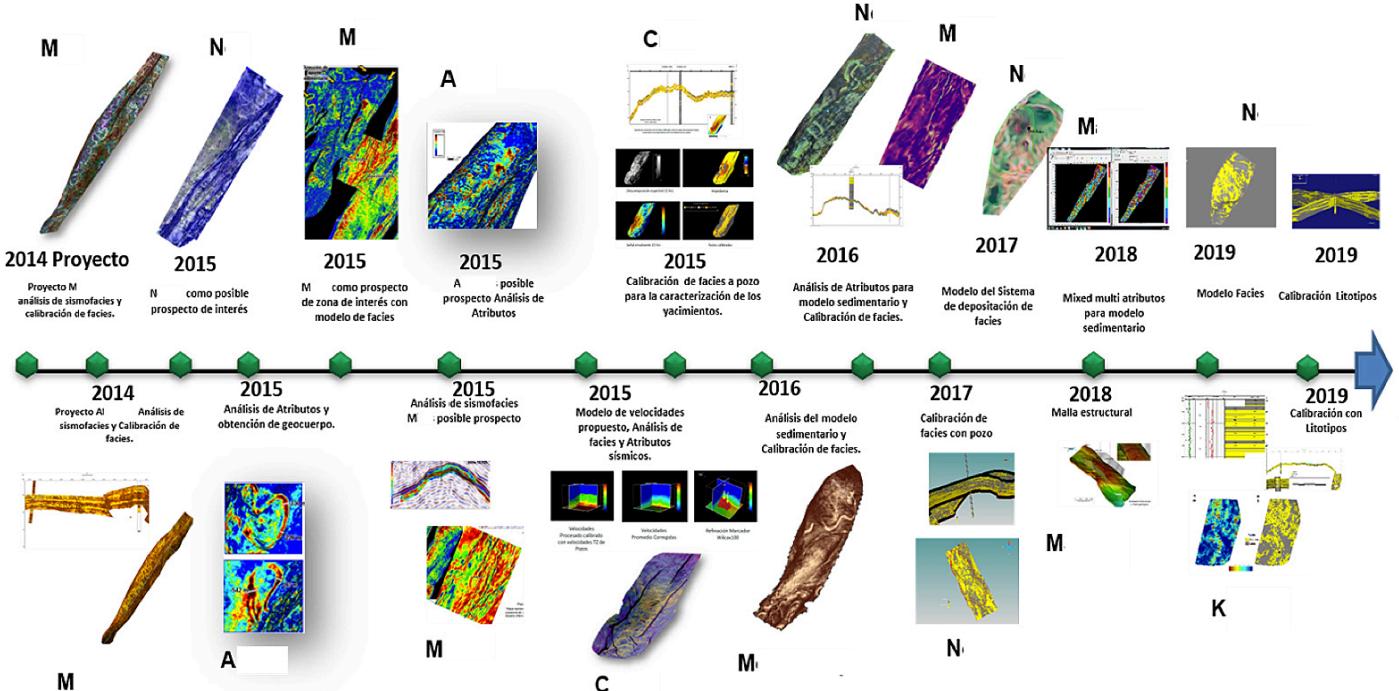


Figura 21. Cronología de estudios realizados con la metodología presentada entre el 2014 - 2019 en el Área Perdido de Aguas Profundas PEMEX, desde la generación de modelos de sismofacies (NNT), hasta los modelos 3D de Litofacies calibrados (Tau).



laborado como soporte técnico y consultoría para la empresa Emerson-Paradigm, impartiendo cursos técnicos en áreas de interpretación, caracterización sísmica y procesos especiales para empresas como PEMEX, y privadas, así como a nivel académico a la Facultad de Ingeniería en la UNAM. Trabajó como consultora técnica y líder de proyecto para la empresa COMESA, prestando servicios para CFE, Bolivian Fiscal Oil Fields, y DS Oil Services, en la generación de oportunidades de perforación para diferentes campos de producción petrolera y geotérmica. Actualmente labora como Geofísica intérprete para la empresa Roma Energy SA de CV.

# Boletín Técnico **AMGE**

S e g u n d a   G e n e r a c i ó n



Asociación Mexicana de Geofísicos  
de Exploración, A.C.

Para someter manuscritos en el Boletín Técnico AMGE  
–Segunda Generación, así como conocer las normas editoriales  
y guía de publicación, favor de comunicarse con alguno  
de los siguientes editores:



Raúl del Valle García

Email: raul.vontal@gmail.com



Efraín Méndez Hernández

Email: emendez2310@gmail.com

